

硕士学位论文

滚动轴承剩余寿命预测算法研究及监测软件 开发

STUDY ON ALGORITHM FOR ROLLING BEARING REMAINING USEFUL LIFE PREDICTION AND DEVELOPMENT OF MONITOR SOFTWARE

陈远航

哈尔滨工业大学
2020 年 6 月

国内图书分类号：TP277
国际图书分类号：621

学校代码：10213
密级：公开

学术硕士学位论文

滚动轴承剩余寿命预测算法研究及监测 软件开发

（学术型）

硕 士 研 究 生：陈远航

导 师：彭高亮 教授

申 请 学 位：工学硕士

学 科：机械电子工程

所 在 单 位：机电工程学院

答 辩 日 期：2020 年 6 月

授予学位单位：哈尔滨工业大学

Classified Index: TP277

U.D.C: 621

Dissertation for the Master Degree in Engineering

**STUDY ON ALGORITHM FOR ROLLING BEARING
REMAINING USEFUL LIFE PREDICTION AND
DEVELOPMENT OF MONITOR SOFTWARE**

(Master of Engineering)

Candidate:	Chen Yuanhang
Supervisor:	Prof. Peng Gaoliang
Academic Degree Applied for:	Master of Engineering
Speciality:	Mechatronic Engineering
Affiliation:	School of Mechatronics Engineering
Date of Defence:	June, 2020
Degree-Conferring-Institution:	Harbin Institute of Technology

摘 要

轴承作为“工业的关节”，其健康状态对机械设备的稳定运行有着极其重要的作用。而对于尽可能避免轴承破坏所造成的损失和降低轴承维护成本之间的矛盾，对轴承进行实时的健康状态监测及剩余寿命预测则是最好的双赢策略，且《中国制造 2025》中亦明确指出应加强设备可靠性技术及其应用的开发。因此，利用现代化技术，展开对滚动轴承退化机理的研究，并对滚动轴承实施智能化监测及剩余寿命预测，具有重要的理论和现实意义。

本文针对滚动轴承全生命信号序列长度过长，不利于神经网络进行训练的问题，提出使用神经网络中的卷积层对信息序列在时间维度上进行压缩，然后使用注意力机制提高循环神经网络处理长序列的能力，最终实现滚动轴承剩余寿命预测。最后通过测试数据的验证，证明了该方法有着更高的准确率，从而表明神经网络结构在滚动轴承剩余寿命预测问题上具备可行性。

然而过于复杂的网络结构往往意味着运行时间较长，尤其是针对超长序列的循环神经网络，这一点不利于实现剩余寿命的实时预测。为此，本文提出使用神经网络优化从滚动轴承振动信号中提取滚动轴承健康状态特征的过程。通过对比基于自编码器和基于对比学习的两种自学习神经网络结构，发现基于对比学习的神经网络能够更加有效地从滚动轴承振动信号提取其健康状态信息。

有了更好的特征表达之后，还应减短神经网络处理的时间序列长度以缩短神经网络运行时间。基于轴承退化规律的考虑，采用对最新信息进行连续采样，久远信息稀疏采样的方法，并使用位置编码的方法保留时间信息，从而保证在缩短时间序列长度的同时，保留足够的滚动轴承健康状态变化信息。然后通过添加正则化的方式，提高网络的预测效果，最终实现在极短的时间内进行较为准确的滚动轴承剩余寿命预测。

最后，使用 C# 语言编写滚动轴承实时监测及剩余寿命预测软件系统，通过使用模块化、接口化编程的方式摆脱软件对于特定数据采集卡的依赖性，并实现数据处理算法的快速开发，然后利用 TensorFlow.net 框架为软件嵌入神经网络算法。最终用数据集模拟信号数据，验证了神经网络算法进行滚动轴承剩余寿命实施预测的可行性。

关键词：滚动轴承；退化规律；剩余寿命预测；深度学习；实时预测

Abstract

The rolling bearing is called “the joint of industry”, whose health state has a great influence on the stability of the machine. Considered the contradiction between the lower risk of disaster caused by broken bearing and the lower cost of bearing maintenance, the best win-win strategy is constantly bearing monitoring and real time remaining useful life prediction. Besides, the first 10-year national plan for transforming China's manufacturing, entitled "Made in China 2025", also clearly pointed out that the technology and the application of machine reliability should be developed. Therefore, it is important to do research on the degradation of bearing and achieve accurate real time bearing remaining useful life prediction with modernization techniques.

Considered the problem that the life-cycle data of bearing is too long to train a well recurrent neural network, this paper proposed to use convolution and attention mechanism. First, life-cycle data are compressed along the time axis to some extent via using convolution, then attention mechanism helps recurrent neural network to deal with a long sequence of data and make a prediction. After tested on the test data, the result proved that it makes a more accurate prediction than other methods, which also shows that artificial neural network is a promising tool in the problem of bearing remaining useful life prediction.

However, such neural networks with complex structure always costs much time, especially the recurrent neural network that deals with over long sequences. This makes it unable to give a prediction in a second. For this reason, this paper suggests to use a neural network to optimize the process of feature extraction from bearing vibration signals. By comparing the self-supervised learning methods based on autoencoder the ones based on contrastive learning, we found that the extracted features from later ones are more representative of the health state of bearing.

After that, the process sequence also should be shorter to reduce the running time of the recurrent neural network. Therefore, based on the degradation theory of bearing, this paper suggests to abandon some old data in the sequence, the older the more are abandoned. And use position encoding to keep the information of time. As a result, this sequence of cycle-life data is shortened but lost little information about the change of

bearing health state. Finally, by using regularization strategies, regLSTM is able to make an accurate prediction for a second.

In the end, a software system for real time bearing health state monitoring and remaining useful life prediction is designed in C#. By using modularization programming method and interface, this software system is less depending on specific data acquisition card and allow rapid development in signal processing algorithms, including the ones based on deep learning thanks for the TensorFlow.net package. Then a test is carried out with test data as simulation input, and the result identified that such neural networks are able to make a real time accurate prediction in bearing remaining useful life.

Keywords: rolling bearing, degradation rule, remaining useful life prediction, deep learning, real time prediction

目 录

摘 要.....	I
Abstract.....	II
目 录.....	IV
第 1 章 绪 论.....	1
1.1 课题背景及研究意义.....	1
1.2 国内外研究现状.....	2
1.2.2 基于统计模型和物理模型的轴承剩余寿命预测方法.....	2
1.2.3 基于数据的轴承剩余寿命智能预测算法.....	4
1.2.4 剩余寿命预测技术的应用现状.....	7
1.3 本文主要研究内容.....	7
第 2 章 轴承剩余寿命智能预测理论基础.....	9
2.1 引言.....	9
2.2 PHM2012 数据集介绍.....	9
2.3 轴承磨损形式及退化规律.....	10
2.3.1 滚动轴承的结构.....	10
2.3.2 轴承典型失效形式.....	11
2.3.3 轴承退化规律分析.....	12
2.4 轴承振动信号的特征提取.....	13
2.4.1 时域信号及其特征.....	14
2.4.2 频域信号及其特征.....	17
2.4.3 时频信号及其特征.....	20
2.5 人工神经网络原理及分类.....	22
2.5.1 全连接.....	23
2.5.2 卷积神经网络.....	24
2.5.3 循环神经网络.....	24
2.6 本章小结.....	26
第 3 章 轴承剩余寿命智能预测算法研究.....	27
3.1 引言.....	27
3.2 特征选择及归一化.....	27
3.3 网络结构.....	28

3.3.1 卷积层	29
3.3.2 基于注意力机制的编码器-解码器结构	29
3.4 网络训练过程	31
3.5 滚动轴承剩余寿命预测流程	32
3.6 测试结果	34
3.7 本章小结	36
第 4 章 轴承剩余寿命预测算法实时性改进	37
4.1 引言	37
4.2 基于自监督学习的特征提取	37
4.2.1 基于自编码器的特征提取	38
4.2.2 基于对比学习的特征提取	39
4.2.3 特征降维可视化对比及分析	41
4.3 轴承剩余寿命实时预测网络	42
4.3.1 端到端的剩余寿命预测	42
4.3.2 特征抽取顺序及位置编码	44
4.3.3 regLSTM 网络	47
4.4 预测结果	48
4.5 本章小结	51
第 5 章 滚动轴承实时监测软件设计及开发	52
5.1 引言	52
5.2 软件功能需求	52
5.3 软件体系框架	53
5.4 软件各功能具体设计及开发	53
5.4.1 数据采集	53
5.4.2 数据存储及管理	54
5.4.3 数据处理	56
5.4.4 警报模块	57
5.4.5 界面设计	58
5.4.6 软件开发及维护	59
5.5 软件实际使用流程	60
5.6 本章小结	60
结 论	61
参考文献	63

攻读硕士学位期间发表的论文及其它成果	70
哈尔滨工业大学学位论文原创性声明和使用权限	71
致 谢	72

第1章 绪 论

1.1 课题背景及研究意义

随着信息存储技术的发展以及人们对信息处理能力的提高,信息技术的应用已经扩张到各行各业当中,信息对整个社会的影响逐步提高,甚至到了举足轻重的地位。尤其在 21 世纪,随着信息技术的发展及扩张,进入大数据时代,信息技术不再只停留在计算机和互联网领域,而是进入更多不同的技术领域中,促进各个行业的迅猛发展。目前,制造业正借着信息技术进行一场巨大的变革。

近年来,制造行业中信息技术的含量越来越重,美国、德国等工业强国分别推出了“工业互联网”、“工业 4.0”等产业政策,力图以大数据技术为支点,提升制造业的整体实力^[1]。而我国虽早已超于美国成为全球第一制造业大国,但其大多数产业的发展都是从国外低技术含量制造行业发展来的,因此具备产业结构不合理、技术含量低、自主创新薄弱等问题,这些问题正是我国制造业水平与欧美传统工业强国的差距^[2]。为了弥补这些差距,我国在 2015 年提出了“中国制造 2025 战略”,以创新驱动、转型升级为核心,全面提升我国制造业发展水平和产品质量^[3]。对于制造企业来说,即要求以智能化制造代替传统制造,并进一步提高改善机械产品全生命周期管理的智能化水平,实现设备故障状态监测与健康管(Prognostics Health Management, PHM),尤其是机械设备中的易损坏的关键零件。国务院所制定的《国家中长期科学和技术发展规划纲要(2006~2020)》中把“重大产品和重大设施寿命预测技术”列为需攻克的 27 项前沿技术之一;《机械工程学学科发展战略报告(2011~2020 年)》中也将重大设备的运行可靠性、安全性、可维护性关键技术列为中要的研究方向^[4]。

据统计,旋转机械设备约占机械设备总量的 80%,且其中超过 60%的机械系统或者设备故障都是由其关键零部件引起^[5],譬如轴承以及齿轮等。滚动轴承又被称为“工业的关节”,机械设备的性能和可靠性与其息息相关。轴承的磨损,轻则引起机械设备的损坏,重则导致严重的生产安全事故,造成人员伤亡和环境破坏^{[6]~[9]}。为此,亟需对轴承进行实时状态监测甚至寿命预测,以提高旋转机械的稳定性和可靠性。然而,滚动轴承的相关试验表明,同一厂家同一批生成的同一型号滚动轴承在相同的工业条件下,在相同的环境下运行,其最短使用寿命与最长使用寿命之间的差值可能达到几十倍^[10]。在传统工业中,为保证机械设备的安全性、稳定性,往往会对机械中的轴承根据经验进行定期更换,这意味着机械设备的检

修管理中普遍存在着“欠维修”和“过维修”的现象^[11]。提高了设备维护成本的同时，对设备的稳定性和可靠性的提高却非常有限。

为了对轴承实现故障预测与健康管理（PHM），许多学者就轴承剩余寿命（Remaining Useful Life, RUL）预测问题提出了许多想法。起初提出的解决方法以退化可靠性模型以及可靠性评估理论为主，但此类理论及方法大多是源于电子产品的可靠性研究，其在机械领域的适用性也有所不同；另一方面，机械产品的可靠性问题往往较电子产品更为复杂，其中原因包括可靠性数据缺乏、产品个体之间差异明显、应力环境复杂、失效模式及功能状态多样、失效影响因素众多^[12]等等。因此对于机械产品来说，在退化模型的评估中，一旦做出不合理的假设，则可能导致评估结果不可信，甚至得到截然相反的结论。

近年来，在工业大数据背景下^[13]，大数据让学者们看到了基于数据驱动的剩余寿命预测算法的可能性，但也带来了全新的挑战：（1）如何有机的结合相似产品的数据，实现实时监测及剩余寿命预测；（2）如何利用深度学习技术减少对专家经验等相关专业知识的依赖，进一步实现自动化，最终实现端到端的预测；（3）针对失效机理尚不明确且失效模型难以构建的复杂设备，怎样才能构建更加泛化的数据驱动方法；（4）提出的算法与实际应用之间仍然缺乏对应软件作为中间连接。本文就轴承剩余寿命预测问题，以滚动球轴承为研究对象，研究剩余寿命智能预测算法，并建立相应软件，实现对滚动球轴承剩余寿命准确的实时预测。

1.2 国内外研究现状

剩余有效使用寿命（RUL），是指组件或系统在替换前能够保证其按照预期目的、功能运行的剩余时间，剩余寿命 $T_{RUL}(t)$ 的定义如下：

$$T_{RUL}(t) = \{T_F(t) - t | T_F(t) > t, Z(t)\} \quad (1-1)$$

其中， t 为机器当前已使用时间， $T_F(t)$ 为失效时间随机变量， $Z(t)$ 为在当前时刻 t 之前该使用对象所有历史使用信息。多年来，人们试图使用各种方法来描述轴承的失效状态与时间的关系，这些方法主要可分为基于统计模型和物理模型的寿命预测方法以及近年来兴起的基于大数据的智能预测算法。

1.2.2 基于统计模型和物理模型的轴承剩余寿命预测方法

基于统计分析的剩余寿命预测的方法主要源于可靠性的理论研究^[14]。首先通过对机械设备进行大量试验，综合其他可能影响因素（如材料性质、工作负载、润滑状态等），获取机械设备的失效数据，然后运用数学统计和概率学等数学知识，对这些数据进行分析和处理，从而获得以可靠性为准则的寿命预测统计学^[15]。

其中,在滚动轴承领域,这类方法中最为经典的要数 Lundberg-Palmgren 模型 (L-P 模型)^[16]、Ioannides-Harris 模型 (I-H 模型)^[17]、Tallian 模型、Zaretsky 模型和 Schlicht-FAG 模型等。这些模型假设轴承疲劳裂纹最初会在滚到材料表面薄弱点出现,然后根据相应的工况计算出该疲劳裂纹的发展趋势,从而预测出剩余寿命。鉴于此类方法,国际标准化组织 ISO 以及我国国标都规定了相应的轴承寿命计算经验公式^{[15][18]}。

然而,该类模型是基于充足的轴承失效数据而建立起来的,其主要关注的是大批量轴承的失效时间分布,所预测出来的也是大批量轴承失效时间的期望值。但是对于不同工况下,不同工作环境条件下的轴承,磨损出现及发展的规律也有所不同,从而导致按照这种模型估计出来的轴承寿命没有任何参考意义^[20]。如在高铁齿轮箱中的轴承,长期处于机器恶劣的工作环境,转速经常达到 6000rpm 以上,与大部分轴承的工作负载都有着较大的差别,往往只能根据实际情况重新设定假设以及建模。

由于事先预测的统计学模型适用性不足,学者们提出一种能根据实时数据进行更新迭代的剩余寿命预测统计模型,其中,自回归 (AR) 模型作为统计学上能够出色处理时间序列并进行预测的方法,自然成为首选。AR 模型能够通过学习历史数据,计算出变量的未来趋势,具备参数识别简单、实时性好、复杂度低等优点。然而,在轴承剩余寿命问题上,要预测轴承的损耗情况则需要先测量出轴承的相关损耗信息,并得到能够体现轴承健康状态的指标,这就意味着轴承剩余寿命预测问题将转变为轴承健康状态特征提取的问题。简单的统计参数例如平均值、均方根值、峰度值、能量值、熵值等,但由于轴承振动信号中往往参杂了大量噪声,这类简单参数在降低噪声和抗干扰方面收效甚微^[3]。申中杰^[21]以轴承振动信号的相对方均根值作为轴承损坏状态的特征指标,并进行剩余寿命预测,取得良好结果。Soualhi A^[22]则利用希尔伯特黄 (Hilbert-Huang) 变换以及希尔伯特边际谱提取了滚动轴承的内圈、外圈以及滚动体的性能退化指标;张亢^[23]等人则提出以数学形态学分形维数和局部均值分解相融合的轴承状态指标。然而由于轴承振动信号中往往包含了大量与轴承状态不相关的噪声,极难形成一种统一有效的轴承状态特征提取方法。

此外,运用断裂力学和疲劳强度相关知识,Paris P 和 Erdogan F^[16]对裂纹扩展规律的临界情况深入研究,提出了著名的 Paris 公式。随着断裂力学的进一步发展,人们开始将此理论对轴承磨损发展进行模拟,提出了相关的轴承剩余寿命预测的物理模型。

严如强^[24]等人基于改进的 Paris 模型对轴承缺陷传播过程进行刻画, 结合 AR 模型和相空间卷曲技术对轴承寿命进行预测。Zio^{[25]-[26]}等人针对测量不确定性下部件的裂纹扩展问题, 通过粒子滤波技术对模型参数进行迭代更新, 实现剩余寿命的预测。Billington^[27]等人则利用 Paris 裂纹增长模型和非线性递归最小二乘法对滚动轴承进行剩余寿命预测。雷亚国等^[28]则将轴承剩余寿命预测分为两个阶段, 首先提出一种基于权重最小化量化误差的健康指标以融合多特征信息, 然后采用极大似然估计方法对基于 Paris 的状态空间模型中的各个参数进行初始化, 通过粒子滤波技术进行参数更新, 最终实现轴承剩余寿命的估计

从以上例子中可以看出, 基于物理模型的剩余寿命预测方法在一些失效机理明确且能够准确刻画的对象上, 能够进行较为准确的预测, 并且通过预先设定好的失效阈值就可以对对象进行实时的剩余寿命预测^[13]。但是, 在现实中, 滚动轴承的实际裂纹扩展极不规则, 难以建立准确的失效模型。

1.2.3 基于数据的轴承剩余寿命智能预测算法

如今, 随着监测成本下降以及信息技术的发展, 每台重要设备每天都产生巨量的监测数据, 这些数据或许对揭示机械设备的退化规律有着极大的帮助。例如, 空客公司在 A350 飞机上部署了超过 6000 个传感器用于实时监测包括燃料流量、压力、温度、飞行高度、飞行速度、外部环境温度的数据, 每架飞机每天都产生高达 2.5TB 的监测数据; 昆仑数据和新疆金风科技有限公司合作开发的风力设备 KMX 大数据平台用来监测风机的实际运行状态, 2 万台风机每秒都产生超过千万条数据; 通用公司对某风力发电厂的风力涡轮机部署了约 50 个传感器, 以对涡轮机组的健康状态进行实时监测^[13]。

同样的, 对轴承进行实时监测的成本也已经下降到能够接受的程度。理论上, 轴承的长期监测信号会包含轴承健康状态的退化规律, 于是人们希望利用对轴承的长期监测数据实现对轴承的剩余寿命估计, 即基于数据驱动的轴承剩余寿命估计。其中最常用的方法包括支持向量机 (SVM)、比例风险模型和隐式马尔科夫模型 (HMM) 以及人工神经网络 (NN)。

支持向量机 SVM 最早是由 Vapnik 等人根据统计学习理论中结构风险最小化原则提出的用于分类的机器学习算法, 它以置信范围最小作为优化目标, 相当于求解一个凸二次优化问题, 并且通过相关核函数的优化, 找到分类问题的中的最优分割超曲面, 从而使得模型具备很好的泛化能力。而支持向量回归机 (SVR) 则是寻找最能够拟合绝大部分数据的超曲面, 从而实现回归以及预测。譬如杨洋^[29]使用遗传算法对 SVM 中的高斯核函数参数和惩罚系数 C 进行优化, 用于预测风电

机组齿轮箱轴承的剩余寿命；于震梁^[30]则将 SVM 和卡尔曼滤波相结合，使用现有的数据训练 SVR，然后根据退化特征构建卡尔曼滤波状态方程，估计剩余寿命；Nieto^[31]利用粒子群算法对 SVM 模型中的惩罚系数 C 、核参数 g 和不敏感误差参数进行优化，从而得到预测轴承剩余寿命的模型；相似的，Pan^[32]通过改进的果蝇算法来对 SVM 的相关参数进行优化。

HMM 描述了由一个马尔科夫链随机生成的不可观测序列，再由这些序列生成的可观测的随机序列的过程，因此它是一个双重随机概率模型。该模型认为，虽然系统状态不能直接观察，但可根据受状态影响的可观察变量进行推理^[33]。HMM 最早应用于语音处理领域，Bunks^[34]等人将其应用到诊断和预测领域。Baruah^[35]等人提出了一种采用 HMM 进行刀具剩余寿命预测的方法，通过传感器采集到的数据对刀具不同的退化状态进行训练和识别；周建民^[36]等人使用 AR 模型对轴承全寿命周期的振动信号提取系数及残差，用正常样本和失效样本建立模糊 C 均值模型，在用 HMM 模型得到退化指标，从而估计出轴承剩余寿命；张旺^[37]等人则使用 Hilbert 包络解调的方法对轴承振动信号进行降噪，从而能够提取出具备轴承损坏趋势的特征，并使用 GHMM 模型进行寿命预测。

虽然 SVR 和 HMM 技术在轴承剩余寿命预测问题上应用广泛，但是由于该类算法相比于基于大数据的深度学习算法来说，仍然不能处理更加复杂的非线性数据，这也就意味着使用该类算法前，仍需要对原始数据进行预处理，包括且不仅限于特征提取、特征选择、特征融合等，这些预处理往往也意味着算法的建立仍然离不开大量的专家知识，离实现自动化，甚至端到端的智能预测算法依然有着较长的距离。

而随着计算机算力的增强，更大更复杂的人工神经网络具备了实现的可能性，而神经网络的强大学习能力也为数据研究者们带来了新的数据处理手段。Gebraeel N^[38]等人将滚动轴承故障频率、谐波振幅等参数，输入到简单的反向传播（BP）神经网络中，通过训练神经网络预测滚动轴承剩余寿命。Guo L^[39]等人则使用循环神经网络（RNN）从轴承振动信号中提取特征，以此表示轴承的退化量，并用指数模型估计轴承剩余寿命。Chen Z^[40]等利用经验模式分解（EMD）得到的能量熵作为特征参数，通过循环神经网络实现机械设备运行状态预测。Runqing Huang^[41]等使用自组织映射（SOM）和 BP 神经网络提取轴承退化指标，用失效时间加权模型来预测球轴承剩余寿命。Giduthuri^[42]等人则提出使用卷积神经网络（CNN）进行轴承剩余寿命估计，其同时处理轴承在不同时间段的振动信号，从而学习轴承在一段时间内的健康发展趋势，并从而预测出轴承剩余寿命。Ren L^[43]则提出将轴

承振动信号的频域、时域以及自编码器压缩之后的特征联合输入到神经网络中进行剩余寿命预测。

从以上例子可以看出，轴承剩余寿命一般可以分为四个步骤，分别是特征提取（选择），构建健康状态指标，使用回归算法拟合回归曲线，根据设定阈值计算剩余寿命，如图 1-1 所示。




图 1-1 数据驱动的轴承剩余寿命预测算法一般过程

根据特征从振动信号的不同表达方式提取可分为时域特征、频域特征以及时频特征。而如果这些特征能够很好的表达轴承健康状态信息，则可以直接用来进行该特征的曲线回归，否则则需要构建健康指标来代替特征，以提高指标随时间曲线的预测稳定性。在曲线回归算法中，马尔可夫模型、支持向量回归（SVR）以及自回归（AR）模型是最为常用的数据驱动的曲线回归算法。但是随着神经网络技术的发展，许多研究表明直接使用神经网络对特征进行回归甚至直接进行剩余寿命预测是可行的，甚至可以有着更低的预测误差。

神经网络对于非线性函数的强大拟合能力让人们一步步减少对专业知识的依赖，是轴承剩余寿命预测实现智能化的希望。然而在实际应用中，神经网络若要学习到较好的轴承退化趋势，则要同时处理轴承全生命周期的数据。但是轴承的特征频率较高，意味着其采样频率高，从而导致轴承的全生命周期监测信号含有非常庞大的数据量，这远远超出了神经网络单次可计算的范围。于是出现了不少折中的方案，譬如数据压缩、特征提取、构建健康指标（HI）等等。这些折中的方法虽然取得了较好的效果，但是仍然没有实现真正的智能化端到端的寿命预测，而且更是难以实现对任意轴承的普适性，甚至于对任意旋转机械的普适性。这些

问题都意味着用于轴承剩余寿命预测的人工神经网络结构仍然需要进一步优化，进一步提高轴承剩余寿命预测的自动化、智能化水平。

1.2.4 剩余寿命预测技术的应用现状

剩余寿命预测方法虽然已经发展多年，并且融合了许多领域的知识，然而仍然缺乏可靠并且能够使用的预测方法，贸然在工业上应用剩余寿命预测技术，其成本远远高于可获得的收益。因此剩余寿命预测技术的研究远远多于其应用。

国内在故障诊断、寿命预测及健康管理等方面主要应用于航空航天、船舶机械、水力发电站等比较复杂的大型设备领域，这些大型重要设备对安全性的要求往往是不计成本的，也促使了最早的故障诊断以及寿命预测技术的发展。而对于普通工业设备，在 2010 年前，信息技术应用成本较为高昂的时候，并未实现任何健康管理方面的技术的应用。而近年来随着信息技术的成本降低，普通工业设备的健康管理项目提上日程，然而国内的相关研究成果与实际设备应用已经形成脱节，从而造成了以剩余寿命预测为主的健康管理技术的一大缺口。

国外则较早应用了相关故障诊断技术。美国早期就将 PHM 系统广泛应用在军事领域方面，其 F-35 的健康管理系统则是 CBM 应用的最高水准。此外，PHM 技术在民用领域的大型设备、工业也有应用，比如民用飞机、复杂建筑、核电站、大型水坝等。其中，在民用航空领域最为突出。最近，很多知名企业如 Impact Technologies、RidegeTop 等也进行了相关的研究。NASA 举办了首届 ISHEM 论坛，方便进学术交流^[44]，电气电子工程师学会（IEEE）更是每年举办 PHM 会议，提供各种实验室以及工业数据集，推动 PHM 技术的发展。

1.3 本文主要研究内容

本文以滚动球轴承为研究对象，针对其振动信号随时间的变化，探究轴承的磨损状态及趋势。提出使用神经网络技术建立端到端的滚动轴承剩余寿命预测算法，并开发对应的软件，从而实现对某机器的滚动轴承实时剩余寿命预测。本文具体研究内容如下：

首先介绍论文的研究背景及意义。通过国家需求、行业需求以及社会需求三方面，阐述在大数据时代对于智能化剩余寿命预测技术的巨大需求。而就目前国内研究现状而言，虽然各类算法百花齐放，但是在实际应用过程中仍然需要面临巨大的挑战，而人工神经网络技术的发展也带来了新的可能。

接下来，以 PHM2012 轴承振动信号数据集为例，分析轴承磨损退化原因及规律，并介绍人工神经网络原理。从轴承结构、运动形式以及轴承失效形式出发，

分析轴承的退化原因及大致表现规律。然后，分析轴承全生命周期的振动信号中常用的时域特征、频域特征和时频特征，以及这些特征能否有效表达轴承健康状态信息，会带给数据驱动算法哪些困难。并提出根据人工神经网络的万能近似原理，如果能够解决轴承全生命周期特征在时间维度上过长的问题，深度学习将是解决这些困难的有效手段。

为此，本文建立了一种基于注意力机制的神经网络模型。通过使用卷积操作和注意力机制解决了普通循环神经网络难以解决像轴承全生命周期信号如此长的序列数据的问题，并在 PHM2012 数据集上证明了该算法的预测效果优于其他文献中所提出的算法。

但是，由于所提出的针对超长序列的循环神经网络结构运行时间较长，不能够满足实时性需求，因此提出改进措施。首先提出使用自学习方法对轴承振动信号进行更好的特征提取，然后提出通过对长序列特征进行特征抽取，并用位置编码保留时间信息，缩短序列长度加快网络运行，最后使用正则化循环神经网络 regLSTM 进行快速准确的剩余寿命预测。

此外，为将该技术应用到实际工程中，使用 C#设计开发 Windows 操作系统下的轴承实时监测软件，功能包括数据采集、数据压缩、数据存储以及使用神经网络算法进行剩余寿命预测等功能，并且能够将相关信息可视化，最后进行实际测试。

第2章 轴承剩余寿命智能预测理论基础

2.1 引言

轴承是支持旋转零部件的关键元件，往往固定在轴承座内部，并做好密封措施防止环境污染，以提高轴承使用寿命。因此，对轴承进行实时的状态分析及剩余寿命预测只能通过间接的方法进行——对外部可检测的轴承信息进行数据分析。其中以轴承振动信号为典型代表。

而为了实现轴承剩余寿命的智能预测，首先需要从轴承振动信号这种复杂信号中，分析轴承的健康状态。为此，需要了解轴承的磨损形式、退化规律以及这些轴承状态信息在振动信号上的表现，从而保证从中提取最能够体现轴承健康状态信息的特征。然后就可以根据人工神经网络原理，构建合适的人工神经网络结构，对这些特征信息进行有效处理，并进行准确的剩余寿命预测。

以下将以 PHM2012 数据集为例，详细分析轴承退化的一般规律，介绍轴承振动信号提取特征的各类方法，探讨这些特征对轴承退化状态的表达能力，以及带给人工神经网络的困难。最后介绍人工神经网络的相关原理。

2.2 PHM2012 数据集介绍

IEEE 协会在 2012 年举办的 PHM 数据挖掘大赛中（PHM2012），提供了一个由 PRONOSTIA 所采集的轴承全周期振动信号的数据集。其轴承全生命周期振动信号的采集装置如图 2-1 所示。




图 2-1 PHM2012 数据采集装置

该装置通过速度传感器以及力矩传感器进行反馈调节保证轴承转速及负载维持稳定，然后通过轴承座上的水平方向（x 轴）以及竖直方向（z 轴）的加速度传感器采集轴承振动信号。

在该数据集中，分为两个训练数据和测试数据，训练数据是完整的轴承全生命周期信号，测试数据则在轴承振动信号幅值发生较大变化时（主观上认为轴承进入退化阶段）取消采集，并给出了轴承最后时刻的剩余寿命。每一个训练或测试数据均对应一个测试轴承。所有测试轴承采用相同的型号，分别在 3 种不同转速及负载的情况下进行，转速以及径向力分别是 1800rpm 和 4000N，1650rpm 和 4200N，1500rpm 和 5000N，对应测试条件 1~3，具体轴承编号如表 2-1 所示。

表 2-1 IEEE 2012 PHM 数据大赛数据表格

测试条件	1	2	3
转速	1800 rpm	1650 rpm	1500 rpm
负载	4000 N	4200 N	5000 N
训练数据	Bearing1_1	Bearing2_1	Bearing3_1
	Bearing1_2	Bearing2_2	Bearing3_2
测试数据	Bearing1_3	Bearing2_3	Bearing3_3
	Bearing1_4	Bearing2_4	
	Bearing1_5	Bearing2_5	
	Bearing1_6	Bearing2_6	
	Bearing1_7	Bearing2_7	

2.3 轴承磨损形式及退化规律

滚动轴承是一种通过将旋转轴与轴座之间的滑动摩擦变为滚动摩擦，减少摩擦损失的一种精密的机械元件。当旋转轴的负载在轴承的设计负载范围内，且保证运行环境足够润滑时，理论上轴承具有较长寿命。然而由于轴承加工、装配误差、整体机械系统与理想状态差别较大等原因，同批量轴承在使用最后会形成不同的损伤形式，具备不同的可使用时间。此处就轴承失效形式及退化规律进行分析。

2.3.1 滚动轴承的结构

如图 2-2 所示，滚动轴承通常由外圈、内圈、保持架以及滚动体四部分组成。其中轴承内圈与旋转轴进行过盈配合；而外圈则与轴承座进行过盈配合；滚动体在轴承内圈与外圈之间的滚道上运动，从而使内外圈实现相对运动，并承受内圈

与外圈之间的径向力以及部分轴向力；保持架则负责使滚动体在运动过程中维持相等间距且互不接触，以保证轴承内圈转动过程中不出现过大的径向运动，以及减少滚动体之间的磨损。




图 2-2 轴承结构图

在一般旋转机械中，滚动轴承最主要承受径向力，滚动体在轴承内外圈之间反复接触、摩擦，且滚动体与内外圈的接触面积小，应力大，因此滚动轴承中滚动体以及内外圈滚道是轴承出现磨损的主要位置。据某机务段详细统计的机车轴承故障中，滚珠及保持架的故障比例为 29.5%，内圈比例为 1.4%，外圈比例为 69.1%^[45]。

2.3.2 轴承典型失效形式

滚动轴承在运转过程中，往往会由于各种原因导致不同型式的失效。常见失效形式有以下六种类型^[46]。

（1）磨损

轴承磨损主要是由滚动体与滚道之间表面接触引起的磨损以及外部侵入灰尘或其他杂质颗粒所导致的。当轴承内部含有杂质颗粒时，轴承磨损会加剧，并产生更严重的擦伤或划痕，从而导致轴承失效。

（2）塑性变形

当轴承由于装配不当或工作负载造成过大冲击或产生高温时，轴承滚动体会与轴承滚道以极大压力进行接触，从而使轴承滚道或滚动体发生塑性变形，称之为塑性变形失效。轴承塑性变形失效根据变形程度大小会对轴承运转产生不同的径向振动，并且会加速轴承的磨损。

（3）胶合

当轴承润滑不足、轴承载荷过大或者安装不当，使滚动体在轴承滚道上进行长时间滑动运动，产生大量热量，使得原本属于一个表面的金属材料涂抹到另一个金属表面上，形成污痕，这种现象称之为胶合。且轴承发生胶合之后，金属材料会由于温度骤变导致材料韧性下降，一旦遇到较大的局部应力时则会转变为断

裂失效。胶合失效主要发生在低速重载设备上，当胶合严重时，轴承滚动体甚至会与轴承滚道粘合在一起，导致设备停止运行。

（4） 腐蚀

轴承表面腐蚀失效包括电介质腐蚀、有机酸腐蚀、电流腐蚀和其他物质腐蚀。轴承受到腐蚀后，腐蚀表面会形成损伤或腐蚀空洞，轻者会加快轴承退化，严重者会阻碍轴承的正常运行。

（5） 剥落

由于各种原因，当轴承滚动体以及滚道表面金属出现剥落时，一般就意味着轴承已经到达了其正常使用的终点。剥落形成的原因可分为物理磨损以及化学腐蚀，物理磨损所造成的剥落一般是金属表面经过长时间的冲击后造成金属疲劳而导致的，化学腐蚀所造成的剥落则与腐蚀失效有关。当轴承出现剥落时，轴承滚动体与滚道表面的滚动接触不再平滑，容易使得轴承发生剧烈的径向振动，影响设备的正常运行，应及时进行轴承更换。

（6） 断裂

轴承断裂时最严重的失效形式。造成轴承断裂的原因一般有两种。一是轴承材料由于材料热处理工艺不当等原因，其内部存在严重缺陷或内部积聚了较大内应力，一旦出现外部冲击，缺陷会之间演变为断裂或者内部内应力瞬间释放形成断裂。二是从外部给予轴承非常大的冲击力产生裂痕甚至断裂。

2.3.3 轴承退化规律分析

轴承在理想工作状态下，一旦滚动体与滚道之间发生磨损，磨损的细微颗粒会加剧磨损过程，轴承性能逐步退化，最终演变为疲劳磨损失效。理想状态下的轴承退化曲线规律如图 2-3 所示，该曲线主要特点有：a) 轴承正常运行时间较长，一般占轴承全生命周期的 80%-90%，在该段曲线区域内，轴承运行过程中存在极为微小的磨损，但这种磨损对其材料性质不造成任何影响，宏观上也不影响机械系统的正常运行；b) 当轴承滚动体或滚道表面出现微小裂纹，轴承开始进入退化阶段，在该阶段内，轴承磨损量逐步增加，一般呈指数形式^[48]，裂纹增大或者产生新的裂纹，在微观上轴承滚动体与滚道的接触会产生集中应力造成更多更大的表面损伤，在宏观上，轴承振动幅度增大，噪声增加，润滑剂温度升高，机械系统精度开始下降；c) 当轴承磨损量累积到一定程度时，轴承损坏，如果拆开损坏轴承，可以明显观察到滚动体或滚道上的磨损痕迹，且机械发生故障的概率急剧增大。若机械继续运行，会存在巨大的风险使机械停转甚至造成灾难。



图 2-3 轴承退化曲线

而在实际工业环境下，当轴承处于正常阶段时，轴承剩余寿命难以进行准确预测，因为存在着许多外部或内部的不可控因素导致轴承内部微小裂纹出现，提前进入退化阶段；而当轴承进入退化阶段时，理论上可以根据退化模型预测轴承的剩余寿命，而且也是充分利用轴承且避免轴承损坏并引起损失的最好方法。但由于不同的工作负载、运行环境，可能会存在一种或多种磨损形式，磨损量随时间的累计速度也会有着较大的差别，且在该阶段中，存在一定可能产生其他裂纹，使退化曲线发生突变性增长。这一系列的不确定因素都增加了轴承剩余寿命准确预测的难度。

例如，有研究学者希望通过微观结构对轴承疲劳寿命进行预测，但近几十年来，通过数值模拟的方法对微观结构模拟并进行寿命预测的有效尝试仍然十分有限^[47]。

2.4 轴承振动信号的特征提取

轴承一般被密封安装在机械内部，在直接观测不可取的情况下，研究学者只能对轴承传出来的信号进行分析。其中，受外部持续性的激励引起的，可反映轴承状态的振动信号是最为常用最为重要的判断依据。轴承振动信号主要由两部分振动组成：一是轴承弹性变形引起的固有振动，与轴承本身的材料、形状、尺寸和质量有关，与轴承的旋转速度无关；二是滚动体经过轴承滚道所产生的振动。

在正常运行期间，轴承滚动体与滚道产生的振动主要是由装配误差、表面波纹度、粗糙度和形位误差等各项误差引起的不稳定的激振力，由于轴承制造精度较高，该类振动一般被固有振动或噪声掩盖；而当轴承处于退化以及损坏阶段时，损坏位置接触表面质量下降，滚动体在损坏位置不断冲击，产生较为明显的低频振动信号。

轴承振动信号中包含丰富而杂糅的轴承状态信息，往往需要进行特征提取才能够观测到轴承健康状态变化。因而用于计算的轴承特征提取的核心要求是，从轴承振动信号中所提取的特征必须包含轴承健康状态信息，而这样的特征一般符合轴承退化曲线规律。以下以 PHM2012 数据挖掘比赛^[49]所使用的轴承全生命周期振动信号为例，就轴承故障特征频率以及振动信号在时域、频域以及时频域的表现进行分析。

2.4.1 时域信号及其特征

时域信号即从轴承座上所采集的原始振动信号。一般来说，从轴承座上采集的振动信号往往混杂着转动机械其他部位的振动信息，只能直观地看出振动幅值的变化，以及在轴承退化期和损坏期可能会存在明显的低频振动现象。

将轴承全生命周期的振动信号进行拼接之后，如图 2-4 所示，在 YOZ 平面上的是轴承全生命周期的振动信号，而在 XOZ 平面上则是取其中 0.1s 时间内的振动信号。从图中振动幅值的变化可以看出，整个生命周期内，轴承约前 95%的时间内处于正常工作阶段，而在后 5%的时间段内，轴承开始退化，并在非常短的时间内进入损坏阶段。而且从整个生命周期来看，轴承振动信号偶尔会参杂着一些突发的脉冲噪声。从退化阶段的振动信号来看，也比较难看出明显的低频振动。




图 2-4 轴承全生命周期振动信号示例图

主要原因是正常情况下的磨损并不是理想状态下的单点损伤，而是会出现大面积的磨损或划痕，如图 2-5 所示。此外也存在多种损伤同时出现并产生耦合振动信号可能。



图 2-5 轴承大面积磨损示例^[50]

在对轴承的时域信号进行分析时，一般通过计算振动信号的一些统计参数作为时域特征并绘制出与时间相关的曲线，从而进行预测。常用的时域特征如公式(2-1)-(2-12)所示。其中峭度、峰峰值和裕度系数对冲击信号较为敏感，可作为轴承进入退化阶段的判据；均方根值的稳定性较好，不易受偶然性的脉冲影响，且其大小一般随着故障程度增加而增大，常用于描述振动信号的趋势变化。以下公式中振动信号 $X = [x_1, x_2, \dots, x_n]$ ，其均值为 $\bar{x}$ ，标准差为 σ 。

1) 均值：

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (2-1)$$

2) 方差：

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (2-2)$$

3) 均方根值：

$$X_{rms} = \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2} \quad (2-3)$$

4) 峰峰值：

$$X_{peak} = \frac{1}{2} (\max(x_i) - \min(x_i)) \quad (2-4)$$

5) 峰态系数：

$$C_k = \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \bar{x})^4}{\sigma^4} - 3 \quad (2-5)$$

6) 峰值因子：

$$C = \frac{X_{peak}}{X_{rms}} \quad (2-6)$$

7) 波形因子：

$$S = \frac{X_{rms}}{\bar{x}} \quad (2-7)$$

8) 脉冲因子：

$$I = \frac{X_{peak}}{\bar{x}} \quad (2-8)$$

9) 偏态系数:

$$C_s = \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \bar{x})^3}{\sigma^3} \quad (2-9)$$

10) 裕度系数:

$$clf = \frac{|\max(x)|}{\left(\frac{1}{n} \sum_{i=1}^n \sqrt{|x_i|}\right)^2} \quad (2-10)$$

11) 峭度系数:

$$K_v = \frac{\frac{1}{n} \sum_{i=1}^n (x - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n x_i^2\right)^2} \quad (2-11)$$

12) 平均信号电平:

$$X_{ASL} = 20 \lg \left(\frac{1}{n} \sum_{i=1}^n |x_i| \right) \quad (2-12)$$

以上轴承振动信号时域特征中, 以均方根值 RMS 最为常用, 其次峭度系数、峰值因子和峰峰值也比较常见。此处以均方根值 RMS 为例, 绘制出轴承竖直方向和水平方向的振动信号的均方根值 RMS 随时间的变化曲线, 其中蓝线表示均方根值 RMS 提取自水平方向的振动信号, 而橙红色线则是竖直方向的, 如图 2-6 所示。




图 2-6 各轴承全生命周期振动信号均方根值 RMS-时间曲线图

从图中可以看出,随着时间增加,轴承振动信号的均方根值 RMS 大致呈单调上升的趋势,能够明显体现出轴承退化曲线规律。但是,当轴承处于健康阶段以及退化早期时,均方根频率并没有一个比较普适的变化规律,如在图 2-6(b)中,有大量明显的噪声;而在图 2-6(c)和图 2-6(d)中,则发现均方根值 RMS 在健康阶段也发生比较剧烈的变化,且水平方向与竖直方向的值有较大差异。另一方面在轴承退化阶段早期,轴承振动信号的均方根值 RMS 变化可能发生不稳定,如图 2-6(f)所示。主要原因是在轴承退化阶段早期,轴承内部开始发生磨损,但是磨损的发展形势具备极大的不确定性,并体现在轴承振动信号。此外,轴承振动信号的均方根值 RMS 在轴承损坏时的取值不一,不利于作为轴承损坏(轴承剩余寿命为零)点的判据。且在轴承衰退晚期,均方根值 RMS-时间曲线的斜率非常高,提高了预测难度,导致预测准确率下降。

然而不可否认的是,均方根值 RMS 仍然是评价轴承健康状态比较重要的指标,比如在国际标准 ISO2372 中,则以均方根值 RMS 进行评价,如表 2-2 所示。

表 2-2 ISO2372 机器振动分级表

振动烈度 (mm/s)	I 类	II 类	III 类	IV 类
0.71	好			
1.12		好		
1.8	满意		好	好
2.8		满意		
4.5	不满意		满意	
7.1		不满意		满意
11.2			不满意	
18	不允许	不允许		不满意
28			不允许	不允许

其中 I 类为功率小于 15Kw 的电机; II 类为 15Kw-75Kw 的电机; III 类为大型原动机(硬基础); IV 为大型原动机(弹性基础),测量值(RMS)为轴承座外壳的三个正交方向上。

2.4.2 频域信号及其特征

频域信号一般指将振动信号进行傅里叶变换之后得到的频谱信号。对于单段振动信号的频谱信号,虽然不能看出振幅随时间的变化,但可以清晰看出轴承振动中能量较大的频率,通过和轴承故障特征频率比较,容易判断出轴承的故障类

型和程度，是轴承故障诊断最常用的方法之一。而对于轴承全生命周期振动信号来说，一般通过滑窗形式对每一小段振动信号进行傅里叶变换，得到轴承振动各个频率幅值随时间的变化也可看出轴承的退化趋势。

常用的频率特征^[48]如公式(2-13)-(2-18)所示，其中振动信号经过离散傅里叶变换之后得到的频谱绝对值为 $y = [y_1, y_2, \dots, y_M]$ ， $M = N/2$ 为频谱长度，而 N 为振动信号长度， f_k 为 y_k 对应的频率值。

1) 平均频率:

$$F_{mean} = \sum_{k=1}^M \frac{y_k}{M} \quad (2-13)$$

2) 中心频率:

$$F_c = \sum_{k=1}^M \frac{y_k f_k}{\sqrt{y_k}} \quad (2-14)$$

3) 均方根频率:

$$F_{rms} = \sqrt{\frac{\sum_{k=1}^M y_k^2}{M}} \quad (2-15)$$

4) 标准差频率:

$$F_{std} = \sqrt{\frac{\sum_{k=1}^M (y_k - F_{mean})^2}{M}} \quad (2-16)$$


5) 频率集中度:

$$F_{fcous} = 1 - \frac{\sum_{k=1}^M |y_k (f_k - F_c)|}{\sum_{k=1}^M y_k f_k} \quad (2-17)$$

6) 频率峭度:

$$F_{fv} = \frac{\sum_{k=1}^M (y_k - F_{mean})^4}{M \cdot F_{std}} \quad (2-18)$$

常用的轴承振动信号频率特征为均方根频率 F_{rms} ，此处亦绘制出 PHM 数据集中轴承全生命周期的均方根频率 F_{rms} -时间曲线，如图 2-7 所示，其变化趋势与时域特征均方根值 RMS 基本相同。这意味着，轴承振动信号的均方根频率同样能够良好地表达轴承的健康状态变化情况，但这也表示在实际的特征选择过程中，为了减少特征的冗余性，一般只需要保留时域特征的均方根值 RMS 就足够了，并不需要轴承频域特征均方根频率 F_{rms} 。


 图 2-7 各轴承全生命周期振动信号均方根频率 F_{rms} -时间曲线图

此外，当轴承开始损坏，即轴承滚道或滚动体出现磨损时，在转速一定的情况下，滚动体以一定的频率经过缺陷部位从而会产生特定频率的冲击振动信号，如图 2-8 所示。因此该频率与轴承自身转速以及缺陷位置有关，称之为“轴承故障特征频率”，是对轴承进行故障诊断的重要参考指标。




图 2-8 轴承故障振动信号

轴承故障特征频率可以根据轴承各元件的相对运动关系推导出来。设滚动球轴承的内圈转动频率为 f_r ，轴承节径为 D ，滚动体直径为 d ，滚动体数量为 n ，这轴承故障特征频率如公式(2-19)至(2-22)所示：

1) 轴承外圈故障频率：

$$f_{BPFO} = \frac{nf_r}{2} \left(1 - \frac{d}{D} \right) \quad (2-19)$$

2) 轴承内圈故障频率：

$$f_{BPI} = \frac{nf_r}{2} \left(1 + \frac{d}{D}\right) \quad (2-20)$$

3) 滚动体故障频率:

$$f_{FTF} = \frac{f_r}{2} \left(1 - \frac{d}{D}\right) \quad (2-21)$$

4) 保持架故障频率:

$$f_{BSF} = \frac{Df_r}{2d} \left(1 - \frac{d^2}{D^2}\right) \quad (2-22)$$

而在实际应用中, 由于轴承的加工误差、装配误差等因素, 轴承的实际故障特征频率也会相对于计算值有所偏移, 使之难以作为轴承退化特征。

除了基于傅里叶变换频谱分析方法之外, 还有倒频谱分析、包络分析和全息谱分析等^[52]。比如通过倒频谱分析所得到的功率谱可以清楚识别出信号所包含的成分, 并通过一定操作突出信号中的周期部分。

2.4.3 时频信号及其特征

由于轴承振动信号是非线性、非平稳的, 且其统计量也是不断随时间变化的函数, 因此轴承振动信号的时域和频域分析有时候是不够全面的^[52]。为此, 提出了时频分析, 即分析频谱信号随时间的变化情况。此类方法在轴承故障诊断以及剩余寿命预测等问题上有着广泛的运用。其中最常用的方法有短时傅里叶变换 (STFT)、小波变换、经验模态分解 (EMD)^[54]、希尔伯特黄变换^[55]等。

其中短时傅里叶变换是由 Dennis Gabor 于 1946 年提出的。其基本思想是, 将信号划分成多个时间间隔, 每个时间间隔可以存在重叠, 对每个时间间隔的信号进行傅里叶变换, 从而获得信号高频带的频幅随时间变化的信息。具体运算公式如公式(2-23)所示, 其中, $x(t)$ 为时域信号, 而 $g(t - \tau)$ 则是中心位于 τ 时刻的时间窗口。

$$STFT_f(t, \omega) = \int_{-\infty}^{\infty} x(t)g(t - \tau)e^{-j\omega t}dt \quad (2-23)$$

以图 2-4 中信号为例, 通过短时傅里叶变换, 该信号垂直方向的振动信号在健康阶段、退化阶段以及损坏阶段的时频图如图 2-9 所示。从图中可以明显看出在健康状态下, 信号并不存在比较明显的高频或低频特征, 而在退化阶段时, 在 1500Hz 下的频率特征上升, 而到了损坏时, 出现了明显的低频特征。




图 2-9 短时傅里叶变换时频图

除了短时傅里叶变换之外，连续小波变换所得到的视频图也是一种应用广泛的方法。且相比于短时傅里叶变换，连续小波变换对于非平稳信号，具有时频窗口可调的性质。在高频部分可获得较好的时间分辨率，在低频部分具有较好频率分辨率，所得到的的小波时频图具有区分轴承退化及故障阶段，反映轴承频率成分的功能。

连续小波变换的公式如下，其 $x(t)$ 中为振动信号， t 为时间， a 为尺度因子，控制频率相关的伸缩变换， b 为时间平移因子。

$$W(a, b) = \int_{-\infty}^{\infty} x(t) \frac{1}{\sqrt{a}} g\left(\frac{t-b}{a}\right) dt \quad (2-24)$$

但是连续小波变换所提取出来的视频图的好坏取决于是否选择最优的母小波以及最优的尺度因子 a 和时间平移因子 b ，这是一项费时费力的工作，且往往需要大量专家知识以及调参经验才能够胜任。

而经验模态分解是黄锬（N. E. Huang）于 1998 年提出的一种自适应信号处理方法，可用于处理非线性及非平稳信号^[54]。该方法的实质是通过特征时间尺度识别信号中所内含的所有振动模态（Intrinsic Oscillatory Mode）。在这一过程中，特征时间尺度及 IMF 的定义都具有一定的经验性和近似性。与其他信号处理方法相比，经验模态分解具备直观、间接、后验、自适应等特点，其分解所用的特征时间尺度是源自于原始信号的^[55]。

经验模态分解的分解过程如算法 1 所示。

表 2-3 经验模态分解过程

算法 1. 经验模态分解

1. 找到信号 $x(t)$ 所有极值点;
2. 用 3 次样条曲线拟合出上下极值点的包络线 $e_{max}(t)$ 和 $e_{min}(t)$, 并求出上下包络线的平均值: $m(t) = \frac{e_{max}(t)+e_{min}(t)}{2}$, 在 $x(t)$ 中减去它: $h(t) = x(t) - m(t)$;
3. 根据预设判据判断 $h(t)$ 是否为 IMF;
4. 如果不是则以 $h(t)$ 代替 $x(t)$, 重复步骤 1-3 直到 $h(t)$ 满足判据, 则 $h(t)$ 是需要的 IMF $C_k(t)$;
5. 每得到一阶 IMF, 就从原信号中扣除它, 重复步骤 1-5, 直到信号最后剩余部分 r_n 就只是单调序列或常值序列。
6. 最后可将原始信号 $x(t)$ 分解成一系列 IMF 以及剩余部分的线性叠加: $x(t) = \sum_{i=1}^N C_i(t) + r_n(t)$

然而在实际应用中, 虽然经验模态分解具备较强的自适应性, 但其分解出来的信号在分解前难以进行定义, 所以采用 EMD 分解信号进行轴承状态判断一般只能由人工进行, 不能实现自动化。

2.5 人工神经网络原理及分类

人工神经网络的历史可以追溯到 20 世纪 40 年代, 是一种模拟生物学习的计算模型^[61]。它从信息处理角度对人脑神经元网络进行抽象, 首先定义大量的神经单元, 每个神经单元会对输入数据进行非线性映射(激活)并输出, 然后将这些神经单元通过一定规律进行连接, 从而可进行数据传递, 组成一个特定结构的神经网络, 即为人工神经网络 (artificial neural network, ANN)。

近年来, 最常用的人工神经网络结构具有以下两个特点: 1) 数据在人工神经元之间进行单向传播; 2) 多个人工神经元组成一层神经单元层, 层内神经元不进行数据传递, 数据在神经单元层之间进行传递。通过诸多神经元的连接, 神经网络中的输入与输出之间形成了一种非线性映射关系。然后, 计算神经网络的输出与理想输出之间的误差, 通过后向传播 (back propagation, bp) 算法, 将该误差通过神经元连接的梯度, 更新网络参数。另一方面, 数据在神经单元层之间流动, 可以更加方便地添加各种层结构进而组成更加复杂, 更加深的神经网络结构, 这也是“深度学习”名称的由来。

通过深度学习, 人工神经网络具备极为强大的学习能力, 能够学习到输入与输出数据之间的极为抽象的联系, 从而成为大数据处理的一大利器, 这一点在计算机视觉、语音识别以及自然语言处理等领域都有所体现, 而在轴承剩余寿命预

测问题上，人工神经网络也开始初露锋芒。下面就几种常用的层连接结构原理进行介绍。

2.5.1 全连接

全连接是人工神经网络最早使用的结构，顾名思义，即每一层中的每一个神经元均与上一层的所有神经元进行连接，信息传递方式为加权求和。典型的深度学习模型多层感知机（multilayer perception, MLP）中的神经元连接模式全为全连接，如图 2-10 所示。




图 2-10 多层感知机（MLP）结构示意图

每个神经元的的信息处理过程可用以下公式表示，其中 $x_{i+1,j}$ 表示神经网络中第 $i+1$ 层第 j 个神经元， $w_{i+1,j,k}$ 表示上一层的第 k 个神经元 $x_{i,k}$ 传递信息到神经元 $x_{i+1,j}$ 的权重， $b_{i,j}$ 表示神经元 $x_{i+1,j}$ 的偏置量，函数 $f(\cdot)$ 表示激活函数。

$$x_{i+1,j} = f\left(\sum_k w_{i+1,j,k} x_{i,k} + b_{i,j}\right) \quad (2-25)$$

如果将公式写成单层神经元的输出形式，则如公式(2-26)所示，其中 $X_{i+1} \in R^M$ ， $X_i \in R^N$ ， $W_{i+1} \in R^{N \times M}$ ， $b \in R^M$ 。

$$X_{i+1} = f(W_{i+1}X_i + b) \quad (2-26)$$

全连接结构可以让该层的每一个神经元都包含上层所有神经元的所有信息，配合非线性激活函数，可以拟合非常复杂非线性关系，Hornik 等人^[62]所提出的万能近似定理清楚解释了以此为基础的多层感知器的强大特征提取能力。此外，由于全连接层可以进行复杂的非线性变换，因此也是自编码器（autoencoder）的最常用结构。自编码器由一个编码器和一个解码器组成，编码器将输入数据转换成一种不同的表示，而解码器则将其转换为原来的形式，通过设置不同的条件可以使输入数据经过编码器之后的尽可能多地保留信息，同时还具备各种好的特性^[61]。

但是全连接结构的连接复杂性也容易造成过拟合以及梯度弥散或梯度爆炸等问题，不利于堆叠多层结构。

2.5.2 卷积神经网络

神经网络中的卷积运算是使用共享权重提取输入信号局部特征的一种运算，用卷积代替全连接可以极大地减少网络参数的同时，能够有效处理具备平移不变性的数据。与数学上的卷积运算不同，神经网络中的卷积运算是对局部区域的数据进行加权求和的过程，且对每个区域权值共享（Weights Sharing），卷积核的权值也就是神经网络所需要学习的参数。具体的卷积运算如公式(2-27)所示。式中 $\mathbf{K}_i^{l(j')}$ 表示第 l 层的第 i 个卷积核的第 j' 个权值， $x^{l(r^j)}$ 表示第 l 层的第 j 个被卷积的局部区域， w 表示卷积核的宽度，具体卷积过程如图 2-11 所示。

$$y^{l(i,j)} = \mathbf{K}_i^l * x^{l(r^j)} = \sum_{j'=0}^{v-1} \mathbf{K}_i^{l(j')} x^{l(j+j')} \quad (2-27)$$




图 2-11 卷积操作示意图

卷积神经网络可以有效处理具备空间平移不变性的数据，即我们关心的是某个特征是否出现而不是它出现的具体位置，比如图像和音频数据。在轴承故障诊断领域中，轴承振动信号中的故障振动信息同样具备时间平移不变性，因此大量学者提出使用卷积神经网络进行故障诊断，并已经取得了一系列的成果^[64]。

2017 年，哈尔滨工业大学的张伟等^[64]提出使用深度卷积神经网络对轴承故障信号进行故障诊断。其提出的一个 7 层的卷积神经网络，通过调整神经网络超参数，使用 dropout 等训练技巧，成功实现了端到端的轴承故障诊断，且具备较好的抗噪能力、泛化能力以及鲁棒性。

这充分说明了卷积神经网络通过足够丰富数据的训练之后，已经能够对轴承振动信号这种复杂的非线性信号进行直接有效的特征提取，并实现端到端的故障诊断功能。

2.5.3 循环神经网络

循环神经网络（recurrent neural network, RNN）^[65]是一种出色的处理不定长度时间序列数据的神经网络结构。它的神经元会按时间序列逐步处理数据，每处

理某时刻的数据都会根据历史时刻的处理结果以及当前时刻的信息来计算当前时刻信息的留存比例，从而更新神经元中保留的历史信息。具体公式如下， $\mathbf{U}$ 、 $\mathbf{W}$ 和 $\mathbf{V}$ 分别是输入层到隐含层、隐含层到隐含层以及隐含层到输出之间的连接权重，而 b 和 c 则是对应的偏置量。一般情况下循环神经网络用 $\tanh(\cdot)$ 函数作为激活函数，从而保证输出在 $[-1,1]$ 范围内。

$$h_t = \tanh(\mathbf{U}x_t + \mathbf{W}h_{t-1} + b) \quad (2-28)$$

$$\hat{y}_t = f(\mathbf{V}h_t + c) \quad (2-29)$$

具体流程如图 2-12(a)所示，然而 Bengio Y^[66]认为普通的循环神经网络结构在处理过长的时间序列时会发生梯度弥散或梯度爆炸的问题，因此后来研究者提出在循环神经元中添加遗忘机制，优化了循环神经网络的信息传递过程，其中以长短时记忆网络（long short-term memory, LSTM）以及门循环单元（Gated Recurrent Unit, GRU）^[67]为代表，如图 2-12(b)和图 2-12(c)所示。




图 2-12 RNN、LSTM 及 GRU 的流程图

长短时记忆网络的公式如下：

$$f_t = \sigma(\mathbf{U}_f x_t + \mathbf{W}_f h_{t-1} + b_f) \quad (2-30)$$

$$i_t = \sigma(\mathbf{U}_i x_t + \mathbf{W}_i h_{t-1} + b_i) \quad (2-31)$$

$$o_t = \sigma(\mathbf{U}_o x_t + \mathbf{W}_o h_{t-1} + b_o) \quad (2-32)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tanh(\mathbf{U}_c x_t + \mathbf{W}_c h_{t-1} + b_c) \quad (2-33)$$

$$h_t = o_t \odot \tanh C_t \quad (2-34)$$

门循环单元的公式如下：

$$r_t = \sigma(\mathbf{U}_r x_t + \mathbf{W}_r h_{t-1} + b_r) \quad (2-35)$$

$$z_t = \sigma(\mathbf{U}_z x_t + \mathbf{W}_z h_{t-1} + b_z) \quad (2-36)$$

$$h_t = z_t \odot h_{t-1} + (1 - z_t) \odot \tanh(\mathbf{U}_c x_t + r_t \odot (\mathbf{W}_c h_{t-1}) + b_c) \quad (2-37)$$

式中， $\mathbf{U}, \mathbf{W}, b$ 均是可训练的参数， $\sigma(\cdot)$ 是神经网络中的激活函数， $\odot$ 是矩阵点乘操作， h_t 是循环神经网络中的隐藏变量（每一层的输出），它表示循环神经网络

学到的历史信息，在处理每一段时间序列前， h_0 置零，每处理一个输入信息 x_t ， h_t 会根据前一时刻的 h_{t-1} 和输入信息 x_t 进行更新并作为该层循环神经元在 t 时刻的输出，而其中的 f_t ， i_t ， o_t ， r_t ， z_t 均是一些隐藏的门单元，通过矩阵点乘操作可以控制信息的流入程度。与普通的循环神经网络相比，长短时记忆神经元和门循环神经元能够有效地根据历史信息以及当前信息确定当前信息的保留比例并进行融合，这在一定程度上缓解了循环神经网络的梯度弥散（梯度爆炸）的趋势，从而可以处理更长的时间序列。

然而，Henaff 等^[68]指出，普通循环神经网络能够处理的序列长度不超过 100，而 LSTM 和 GRU 能够有效处理的序列长度约为 100~200，通过参数调优可使处理长度提高到 400~700。而轴承的寿命差距较大，从 10^2 到 10^6 小时不等，这就意味着循环神经网络需要具备处理长度相差较大的时间序列的能力。

Arnaz Malhi 等^[69]人在 2011 年提出使用循环神经网络对轴承剩余寿命进行预测。其从振动信号及其连续小波变换中提取统计量作为退化特征值，然后训练一系列循环神经网络，预测这些特征值随时间的发展趋势，最后通过整合这些预测结果进行轴承剩余寿命预测。

刘晓飞^[53]首先根据相似相关性从轴承振动信号的时域、频域以及时频域的多个特征参数中选取了时域 RMS、频域 RMS 等 9 个特征参数，使用 LSTM 网络进行剩余寿命预测。

2.6 本章小结

本章以 PHM2012 数据集为例，通过对轴承退化规律的总结，对各类轴承振动信号特征提取方法进行分析，发现常用的轴承特征提取方法所提取出来的特征，虽然从轴承全生命周期来看能够有效表达出轴承的健康退化状态及趋势，但是在轴承退化阶段早期，甚至是轴承健康阶段，这些特征的变化受噪声等因素影响着较大的不确定性，不利于使用传统回归方法进行剩余寿命预测。而人工神经网络凭借其强大的学习能力，则是解决这些问题的强力手段。但是，神经网络的一些局限性也意味着我们需要构建出合适的神经网络结构才能够实现轴承剩余寿命的智能预测。

第3章 轴承剩余寿命智能预测算法研究

3.1 引言

由于轴承失效形式多样，轴承损坏也没有统一标准，从轴承振动信号中提取的各类特征信息随时间的变化也很难用确定的数学模型进行描述。而且轴承退化发展的随机性也阻碍了大量轴承剩余寿命预测方法的应用。

近年来，随着计算机计算能力的提升和人工智能技术的发展，人们开始使用以深度学习为代表的更加复杂的机器学习方法来处理复杂数据，其中在计算机视觉领域的应用最为成功^{[57]-[58]}，而在其他领域，深度学习算法也表现优异^{[59][60]}。对于轴承振动信号这种包含复杂信息且难以分离的信号，不少研究者也从深度学习上看到了，轴承故障诊断以及剩余寿命预测实现自动化的可能。

本章提出使用基于注意力机制的循环神经网络结构，实现轴承剩余寿命的智能预测，并以 PHM2012^[49]数据挖掘大赛中的数据为例，对剩余寿命预测结果进行评价。

3.2 特征选择及归一化

轴承振动信号过于冗余，而特征提取则是一种极为有效的数据压缩方式，能够极大减小数据驱动算法的计算压力。但是所选择特征的对轴承健康信息的敏感程度以及普适性一直以来都难以同时兼顾。

西安交通大学的雷亚国教授^[39]发现轴承振动信号频域中的带谱能量值相比于其他特征参数具有较好的稳定性，且其计算过程不需要任何调节的参数。其具体计算公式如公式(3-1)所示。对于在 i 时刻的一段振动信号 $x_i(t)$ ，其频谱为 $X_t(f)$ 。由于快速傅里叶变换是离散的，且可计算的最高频率遵循采样定理，为采样频率的一半。设频谱的最高频率为 F_{max} ，则可将其划分为若干子频谱带，分别为 $[i \times F_0, (i+1) \times F_0]$ ，其中 $i = 0, 1, \dots, N-1$ ，满足 $F_{max} = N \times F_0$ 。则每一个子频谱的能量值 $E_{t,i}$ 可由公式(3-1)计算。

$$E_{t,i} = \frac{1}{F_0} \int_{i \times F_0}^{(i+1) \times F_0} X_t(f) df \quad (3-1)$$

从轴承振动的原理分析，若不考虑环境因素和机械设备对轴承振动信号的干扰，当轴承处于健康状态时，轴承振动信号除去随机噪声外，最明显的特征频率必然和轴承的转速有关，而轴承转速的变化一般来说是缓慢且微弱的，反映到频

谱上，一段子频带的能量值的变化量则微乎其微。而当轴承进入退化阶段甚至损坏阶段时，轴承故障特征频率及其高频激振频率会逐渐凸显，且与正常阶段的激振频率有较大不同。由于故障特征频率会因为各种实际因素发生偏离，采用子频带能量值则可以有效避免这些偏离带来的影响。

此外，为了减少神经网络的训练阻力，对该能量向量 $E_{t,i}$ 进行归一化，将其限定到[0,1]区间内，计算过程如公式(3-2)所示，归一化后的能量值用 $\widetilde{E}_{t,i}$ 表示。

$$\widetilde{E}_{t,i} = \frac{E_{t,i} - \min_{0 \leq i < 5}(E_t)}{\max_{0 \leq i < 5}(E_t) - \min_{0 \leq i < 5}(E_t)} \quad (3-2)$$

此处考虑特征的长度，以及PHM数据集中轴承振动信号的采样频率(25.6kHz)，则频谱的最高频率为12800Hz，因此设定子频带长度为2560Hz，总共分为5各子频带区间。

3.3 网络结构

网络结构图如图 3-1 所示，由于轴承全生命周期信号在时间维度上的长度较长，首先采用卷积层对其进行压缩，使特征信息的时间维度长度能够在循环神经网络能够有效处理的范围内，然后使用一层双向 GRU 提取特征随时间的变化的信息，即编码器的输出，最后使用带注意力的 GRU 作为解码器，利用注意力机制给出特征序列各个时刻的健康状态值。




图 3-1 网络结构示意图

该神经网络的具体参数如表 3-1 所示。

表 3-1 基于注意力机制的循环神经网络参数设置

参数设置	
卷积层	卷积核大小: 8; 卷积核步进距离: 5; 卷积通道数: 64; 激活函数: PReLU
双向 GRU	隐藏神经元数量: 200;
解码器 GRU	隐藏神经元数量: 200; 注意力计算方式: concat
损失函数	均方误差: $L = \frac{1}{N} \sum_{t=0}^N (y_t - \hat{y}_t)^2$
训练优化器	Adam 优化器, 学习率为 0.005

3.3.1 卷积层

人工神经网络中的卷积操作是一种有效提取局部信息，并对输入数据进行压缩的运算。此处提出在特征的时间维度上进行卷积操作，通过训练，一方面可以有效地从局部的连续特征参数中寻找出轴承由健康阶段进入损坏阶段的转折点，另一方面则可以较大地压缩特征参数在时间维度上的长度。以 PHM2012 数据为例，其中最长的轴承全生命周期的振动信号共有 2.8×10^3 段，即其特征参数的时间维度的长度为 2800，经过步进距离为 5 的卷积层之后，其时间维度上的长度大致压缩到 560，接近循环神经网络可处理的长度极限。

3.3.2 基于注意力机制的编码器-解码器结构

循环神经网络中的编码器-解码器结构最初是由 Cho^[70]提出，并使用在自然语言翻译问题上的一种神经网络结构。这种神经网络结构由编码器和解码器组成，其中编码器负责提取输入序列的上下文（context）信息 $\mathbf{c}$ ，而解码器则根据上下文信息 $\mathbf{c}$ 以及前一序列的数据，逐一计算出输出序列，具体过程如图 3-2(a)所示，对于某一序列位置 t 的输出 y_t 可以由公式(3-3)表示：

$$P(y_t | y_{t-1}, y_{t-2}, \dots, y_1, \mathbf{c}) = g(h_t, y_{t-1}, \mathbf{c}) \quad (3-3)$$

其中 h_t 表示 t 时刻的隐藏层的信息， $g(\cdot)$ 是激活函数。对于输出来说， t 时刻的输出 y_t 是该时刻的隐藏层信息 h_t 、上一时刻输出 y_{t-1} 以及输入上下文信息 $\mathbf{c}$ 的函数。其中来自上一时刻输出 y_{t-1} 的信息保证了当前时刻输出 y_t 与 y_{t-1} 的连续性，而输入数据的上下文信息 $\mathbf{c}$ 保证了 y_t 的准确性。

然而，从网络结构上看，编码器和解码器可以看作一个连续的循环神经网络，因为编码器和解码器的链接方式与循环神经元处理前后序列数据的连接方式是一致的。这就导致了编码器和解码器结构仍然具备循环神经网络的缺点——面对超长序列容易出现梯度弥散或梯度爆炸，这一点在轴承剩余寿命预测问题上是不可接受的。




图 3-2 编码器-解码器结构及注意力机制示意图

为了解决这一困难，luong^[71]引入了注意力机制，如图 3-2(b)所示。引入注意力机制实际上相当在全局信息 c 参与输出计算前加一道门 a ，这道门 a 将会根据 t 时刻输入数据 x_t 来确定在计算 t 时刻输出 y_t 时，全局信息 c 中哪一部分内容更为重要，即告诉神经网络在计算输出 y_t 时，那一部分全局信息最值得关注。从而在计算输出时对全局信息 c 进行更加有效的使用。注意力机制的具体公式如下所示：

$$P(y_t | y_{t-1}, y_{t-2}, \dots, y_1, c) = g(h_t, y_{t-1}, (a_t \cdot \bar{h})) \quad (3-4)$$

$$a_t(s) = \text{align}(h_t, \bar{h}_s) = \frac{\exp(\text{score}(h_t, \bar{h}_s))}{\sum_{s'} \exp(\text{score}(h_t, \bar{h}_{s'}))} \quad (3-5)$$

$$\text{score}(h_t, \bar{h}_s) = \begin{cases} h_t^T \bar{h}_s & \text{dot} \\ h_t^T W_a \bar{h}_s & \text{general} \\ v_a^T \tanh(W_a [h_t; \bar{h}_s]) & \text{concat} \end{cases} \quad (3-6)$$

式中， h_t 是解码器在 t 时刻的输出变量， $\bar{h}_s$ 则是编码器在 s 时刻的输出变量， $\text{score}(h_t, \bar{h}_s)$ 则是通过某种方式计算出 s 时刻的输入信息对于 t 时刻输出的重要性，最后通过 softmax 函数来对这些重要性比重进行归一化，作为 t 时刻的注意力门 a_t 。这一注意力门 a_t 与编码器输出 $\bar{h}$ 进行点乘操作，允许与 t 时刻输出计算相关性最重要的信息流入，阻碍不重要信息的流入。其中计算 $\text{score}(h_t, \bar{h}_s)$ 有三种方式， W_a 和 v_a 均是网络中可训练参数。

从信息流动的角度来看，引入注意力机制之后，对于每一时刻的输出 y_t 与输入数据 x_t 之间有了更短的信息传输路劲，减少了在神经网络训练过程中梯度传递的距离，有效缓解循环神经网络中梯度弥散或梯度爆炸等问题。

而对于轴承全生命周期的特征参数来说，从第二章中各类特征的分析可以看出，数据驱动算法能否学习特征的全局变化趋势是轴承剩余寿命预测是否准确的关键，特征的局部变化趋势反而存在大量噪声。另一方面经过卷积层压缩之后，虽然长度减少了，但仍然较长。因此提出使用双向 GRU 网络作为编码器，保证编码器的输出 $\overrightarrow{h_s}$ 包含了从正反两个方向上传递过来的数据信息，进一步提高信息在时间维度上的全局交流。最后使用带注意力门的单层 GRU 网络作为解码器，概览全局信息的同时，有目的的提取有效信息，进行准确的轴承健康状态指标的预测。

3.4 网络训练过程

由于轴承剩余寿命的最终目的是在轴承退化阶段早期实现准确的剩余寿命预测，因此为了让神经网络实现这一点，我们对训练数据进行时间长度的截取，如图 3-3 所示，将随机选取轴承全生命周期中的一段包含正常阶段以及退化阶段的数据作为输入。然后将从这段长度的轴承振动信号提取出来的子频谱带能量值特征序列作为神经网络的输入。如此一来，从某种程度上算是一种数据增强（Data Argumentation）的措施，可以降低神经网络在训练过程中出现过拟合现象的可能性，提高神经网络在测试数据上的预测效果。




图 3-3 训练数据获取

考虑到轴承的退化规律，即在轴承的全生命周期中，健康阶段占据绝大部分时间，而退化阶段和损坏阶段只占最后时间的一小部分。因此在选取随机长度的振动信号时，本文将起点选取的随机范围设置为轴承全生命周期的 0%到 50%区间段内，而终点的随机范围设置为轴承全生命周期的 75%到 100%区间段内。

此外，轴承剩余寿命一般以秒为单位，因此其数量一般较大，而神经网络在处理差值较大的数据容易引起梯度问题，因此将剩余寿命放缩到[0,1]区间，作为轴承健康状态指标（HI, health indicator），其计算公式如下，设训练数据中轴承的最初寿命为 RUL_0 ，在 t 时刻的剩余寿命为 RUL_t ，则该时刻的轴承健康状态指标为 HI_t 。最后使用最小二乘法根据预测出来的一系列 HI_t 值进行线性回归，从而得出轴承剩余寿命。

$$HI_t = \frac{RUL_t}{RUL_0} \quad (3-7)$$

最后使用最小二乘法根据预测出来的一系列 HI_t 值进行线性回归，从而得出轴承剩余寿命，如图 3-4 所示。具体公式如下，存在参数 a 和 b ，使得一次线性函数 $y = at + b$ ，令 $L = \sum(y(t) - HI_t)^2$ 最小。那么根据最小二乘原理，可求得参数 a 和 b ，如公式(3-8)和公式(3-9)所示。那么根据该线性函数，轴承健康状态指标 HI_t 将在 $t_{end} = b/a$ 时达到 0，即轴承损坏，因此轴承在 t 时刻时，其预测寿命 $\widehat{RUL}$ 则可由公式(3-10)得到。




图 3-4 轴承健康状态指标 HI 计算剩余寿命 RUL 过程

$$a = \frac{\sum_{i=0}^N t_i HI_i - (N+1)\bar{t}\bar{HI}}{\sum_{i=0}^N t_i^2 - (N+1)\bar{t}^2} \quad (3-8)$$

$$b = \bar{y} - a\bar{t} \quad (3-9)$$

$$\widehat{RUL} = \frac{b}{a} - t_N \quad (3-10)$$

3.5 滚动轴承剩余寿命预测流程

以 PHM2012 数据为例，整个剩余寿命预测流程如图 3-5 所示。从试验设备上持续（或等时间间隔）采集的竖直方向和水平方向轴承振动信号，将该信号进行快速傅里叶变换，并提取 5 个子频谱带的能量值，每一小段振动信号（包括竖直方向和水平方向）中可提取出 10 个能量值，然后将这 10 个能量值归一化到 $[0,1]$ 区间，作为一个 10 维的特征变量。接下来将这一系列的特征输入到训练好的神经网络模型中，神经网络将输出一系列轴承健康状态值 HI_t ，最后根据这一系列的轴承健康状态值 HI_t 进行线性回归，从而计算得到轴承剩余寿命预测值。




图 3-5 剩余寿命预测流程图

3.6 测试结果

PHM2012 数据中包含一部分测试数据，该类数据在轴承振动信号出现退化阶段的征兆就截止采集，因此可以通过比较数据停止采集时刻的真实剩余寿命以及预测剩余寿命来检验算法的有效性。其比较结果如图 3-6 及表 3-2 所示。




图 3-6 基于注意力机制的剩余寿命预测算法在 PHM2012 测试数据中的测试结果图

在图 3-6 中，半透明蓝色三角形斜边表示真实的 HI_t 值下降曲线，而半透明红色三角形斜边表示预测 HI_t 值的下降曲线，延长线均为线性拟合出来后的回归直线，其交于 XOY 平面上，可计算预测剩余寿命与真实剩余寿命的误差。因为轴承在损坏前更换比损坏后更换的损失要小，因此将预测剩余寿命小于真实的标记为绿色，预测剩余寿命大于真实的标记为红色。可以看出，该剩余寿命预测算法具备较高的预测准确性，大部分测试轴承的剩余寿命预测误差较小，唯有其中两个的预测误差较大（Bearing1_7，Bearing2_3）。

为了量化该结果，在 PHM2012 大赛中给出了 3 个指标，分别是平均相对误差 $\overline{Er}$ ，平均绝对相对误差 $|\overline{Er}|$ ，以及预测结果实用性成绩 $Score$ ，其计算过程如下所示。

$$Er_i = 100 \times \frac{ActRUL_i - \widehat{RUL}_i}{ActRUL_i} \quad (3-11)$$

$$A_i = \begin{cases} \exp(-\ln(0.5) \cdot (Er_i/5)) & \text{if } Er_i \leq 0 \\ \exp(+\ln(0.5) \cdot (Er_i/20)) & \text{if } Er_i > 0 \end{cases} \quad (3-12)$$

$$Score = \frac{1}{N} \sum_{i=1}^N A_i \quad (3-13)$$

对于每个测试数据，先计算预测结果的相对误差 Er_i ，然后再计算总体的平均相对误差 $\overline{Er}$ ，平均绝对相对误差 $|\overline{Er}|$ ，然后根据相对误差 Er_i 的正负，来计算预测结果实用性成绩 $Score$ ，其结果如表 3-2 所示。通过对比文献[28]、[65]以及[72]–[74]所提出算法的测试结果，可以发现，该算法的预测结果平均相对误差较小，说明准确性高，但平均绝对相对误差较大，说明其稳定性（精密度）较低，仍需改进。

表 3-2 基于注意力机制的剩余寿命预测算法在 PHM2012 测试数据中的测试结果

测试轴承编号	已运行时间 (s)	剩余寿命 (s)	预测剩余寿命(s)	相对误差 Er	$Er[65]$	$Er[72]$	$Er[73]$	$Er[28]$	$Er[74]$
Bearing1_3	18010	5730	5293.5	7.62	43.28	37	54.73	-0.35	-1.04
Bearing1_4	11380	339	873.6	-157.71	67.55	80	38.69	5.6	-20.94
Bearing1_5	23010	1610	2778.39	-72.57	-22.98	9	-99.4	100	-278.26
Bearing1_6	23010	1460	1446.4	0.93	21.23	-5	-120.07	28.08	19.18
Bearing1_7	15010	7570	1060.6	85.99	17.83	-2	70.65	-19.55	-7.13
Bearing2_3	12010	7530	1412.4	81.24	37.84	64	75.53	-20.19	10.49
Bearing2_4	6110	1390	1264.4	9.04	-19.42	10	19.81	8.63	51.8
Bearing2_5	20010	3090	2218.9	28.19	54.37	-440	8.2	23.3	28.8
Bearing2_6	5710	1290	968.5	24.92	-13.95	49	17.87	58.91	-20.93
Bearing2_7	1710	580	469.5	19.06	-55.17	-317	1.69	5.17	44.83
Bearing3_3	3510	820	802.9	2.09	3.66	90	2.93	40.24	-3.66
$\overline{Er}$				2.62	12.20	-38.64	6.42	20.89	-16.08
$ \overline{Er} $				44.49	32.48	100.27	46.32	28.18	44.28
Score				0.4384	0.2631	0.3066	0.3829	0.4285	0.3550

为了检验该算法的实际可使用性，以测试数据 Bearing1_4 和 Bearing3_3 为例，分别预测这些数据在 1/5, 2/5, 3/5, 4/5, 5/5 的剩余寿命，并使用 4 阶多项式进行拟合，结果如图 3-7 所示。可以看出当轴承处于健康阶段时，其预测出来的剩余寿命往往很低，趋近于 0，而当进入退化阶段时，预测剩余寿命曲线开始上升直至与实际剩余寿命相近，然后开始下降。

这一现象可以从神经网络的运行机制进行解释。由于轴承处于退化阶段时，剩余寿命才有可预测的可行性，而该神经网络训练时训练数据也是包含了退化阶段的特征参数，因此该神经网络能够有效拟合轴承在退化阶段到损坏阶段的剩余

寿命曲线，但是对于只包含正常阶段振动信号的数据来说，其预测结果往往是趋向一个极端，在该网络中，由于其输出值限定为 $[0,1]$ 区间，因此所预测出来的结果则趋向于 0。这表明，建立一个实现实时预测的算法仍然需要进一步研究。




图 3-7 基于注意力机制的剩余寿命预测算法实时预测结果

3.7 本章小结

本章提出了基于注意力机制的轴承剩余寿命预测算法，并在 PHM2012 数据集中进行了测试，表明该算法相比于其他算法具备更高的准确率，证明了神经网络算法在轴承剩余寿命预测问题上有着更大的优势。但是，从多个测试结果来看，该算法稳定性仍然不足，且由于该神经网络基于循环神经网络，在预测剩余寿命时，需要对长时间序列数据进行逐一处理，处理时间较长，最终结果也不满足实时性需求，这说明要实现轴承剩余寿命实时预测仍需要进一步研究。

第4章 轴承剩余寿命预测算法实时性改进

4.1 引言

为实现更加准确有效的轴承剩余寿命实时预测，本章对上一章节提出的轴承剩余寿命预测算法提出以下改进方法。使用自监督学习方法，对振动信号进行有效地信息压缩以及轴承退化特征提取，从而能够使用部分轴承历史信息实现准确地轴承剩余寿命预测，加快神经网络的预测速度，进而实现预测实时化。

4.2 基于自监督学习的特征提取

自监督学习的概念是从无监督学习中引申出来的，其本意是神经网络仅根据无标记的数据学习到一些通用的特征表达用于之后的任务。这种自监督学习模式能够有效地学习大量无标记数据或者标记本身不准确的数据的特征分布，并进行特征提取，为之后的特定任务提供巨大的帮助。相比于使用各种数学统计量作为数据特征，自监督学习所提取的特征往往可以根据具体问题进行调整，从而使其提取出来的特征更加适用于该问题。

比如在轴承剩余寿命预测问题上，就找不到能够有效量化轴承健康状态的特征。例如，用轴承剩余寿命来进行标记轴承健康状态就不是一个好的选择，首先人为标定的剩余寿命值存在人为因素误差，其次由于轴承退化阶段的不确定性，相同剩余寿命下所对应的轴承健康状态也不一样，这也正是众多研究者试图通过各种理论建立轴承健康指标的原因。

此外，轴承振动信号中并非所有信息都与轴承健康状态有关，比如在本文第二章中，各种特征中除了含有轴承健康信息，也包含着其他无关的信息（与轴承健康状态变化的相关性较低）。而且所提取的特征与轴承健康状态的相关性也难以衡量，例如，文献^[75]中使用 R 指标评价特征的单调性；文献^[76]中使用 FastICA 对信号进行盲分离等。

而使用自监督学习代替数学统计量对轴承振动信号进行特征提取，则可以利用大数据的优势，智能化提取更能体现轴承健康状态的特征。一方面可以提高轴承剩余寿命预测的智能化程度，减少人工筛选轴承健康特征的工作量，另一方面，使用神经网络进行特征提取可以限定特征的数值范围。相比于振动信号中各类时域特征以及频域特征之间数值变动范围相差极大，且往往不能确定上下界，使用神经网络提取的归一化特征能够让神经网络进行更加有效的处理。最重要的是，

在算法实际使用中，可以实现轴承振动信号压缩的同时提高神经网络预测轴承剩余寿命的速度，在对预测准确率影响较小的情况下，最终实现剩余寿命预测的实时性。本节设计了两种不同形式的特征提取器，通过比较选择较好的特征提取器。

4.2.1 基于自编码器的特征提取

最早用来进行特征提取的自监督神经网络是自编码器，其原理如图 4-1 所示，通过使解码内容与原信息尽可能相似，保证编码内容（特征）尽可能多的保留信息。之后，还出现了变分自编码器（variational auto encoding, VAE）^[77]，保证特征的分布符合正太分布，以便提高之后神经网络的效果。




图 4-1 自编码器结构示意图

然而一般的基于自编码器的特征提取在轴承剩余寿命预测问题上效果并不如意，主要原因在于自编码器体系的特征提取器要求特征必须尽可能的包含原始数据的所有信息，这点性质往往会给所提取的特征带来诸多与轴承剩余寿命相关性低的信息，从而干扰剩余寿命预测。

为了排除特征中我们不想要的信息，Jakab T^[78]提出了一种基于自编码器结构的焦点捕捉模型。其核心思想是构建两个编码器，其中一个负责提取同一序列数据之间的共同特征，另一个则负责提取变化特征，称之为焦点特征，而解码器则是根据共同特征以及焦点特征的组合来进行解码还原。如果通过训练神经网络，使解码器能够根据不同的焦点特征以及相同的共同特征解码还原出不同排序位置上的原始数据，那么就表明焦点特征编码器是一个有效提取序列信息中变化信息的特诊提取器。

此处则基于该思想建立类似的神经网络模型，如图 4-2 所示，本文使用卷积神经网络对轴振动信号进行特征提取，包括整体特征和焦点特征，由于对于轴承振动信号难以确定焦点形式，因此通过将焦点特征的信息熵来衡量焦点信息含量，并将其加入到神经网络训练的损失函数之中，从而使焦点特征包含的信息尽可能少，即令焦点特征更加纯粹。




图 4-2 基于自编码器的焦点特征提取器训练网络图

此外，轴承全生命周期振动信号与视频图像不同，轴承健康状态的变化是非常缓慢的，尤其当轴承处于健康阶段的时候更是如此，因此该网络训练过程中，原始数据和目标数据间隔的样本数为从 1 到 64 的随机数，从而保证网络能够学习到一些长期变化的焦点特征。

4.2.2 基于对比学习的特征提取

除了基于自编码器的自监督学习之外，还有基于对比学习(contrastive learning)的特征提取方法，这种方法不关注特征能否还原原始信息，而是通过特征之间的对比来保证特征需要包含我们所需要的信息，其基本思想是利用样本之间的约束关系来给与神经网络一些“标签”。实际训练过程中，对于任一训练样本 x ，将其其他相似的样本定义为正样本 x^+ ，而不相似的样本为负样本 x^- ，而我们所期望的特征提取器所提取的特征也应满足公式(4-1)，从而将问题转化为分类问题。

$$\text{score}(f(x), f(x^+)) \gg \text{score}(f(x), f(x^-)) \quad (4-1)$$

而对于理想的轴承健康状态特征信息，会具备两个特性，分别是连续性以及可预测性。因此，针对这两个特性，本文分别建立两种自学习模型来试图从轴承振动信号中提取满足的特征信息。

首先是连续性，借鉴 Sermanet^[79]所提出的思想，本文建立卷积神经网络结构作为特征提取器 $G(\cdot)$ ，那么所提取出来的特征也应具备连续性。即对于任意一段特征序列，都可以轻易分辨出该段序列特征连续与否。具体训练过程如图 4-3 所示，特征提取器 $G(\cdot)$ 从有序的序列信号中分别提取特征，建立一个卷积神经网络作为判别器，而当这些特征维持原有顺序时，判别器应输出 1，而当打乱这些特征的顺序之后，再次输入到判别器中，则应输出为 0。




图 4-3 保证特征连续性的对比学习方法

而对于可预测性，则要求所提取的特征同样具备可预测性，从条件概率的角度来说，即要求最大化条件概率 $p(x_{t+1}|x_{t-N}, \dots, x_t)$ ，若将 $[x_{t-N}, \dots, x_t]$ 的信息融合为上下文信息 $\mathbf{c}$ ，那么该条件概率可简化为 $p(x|\mathbf{c})$ 。但是 Aaron^[80]等人认为直接通过条件概率方程 $p(x|\mathbf{c})$ 来探索数据 x 和上下文信息 $\mathbf{c}$ 之间的关系并不是一个有效的方案，因此可以通过最大化未来数据 x_{t+k} 和上下文 $\mathbf{c}$ 的表征交互信息的方法来抽取输入数据 x 共享的潜在特征：

$$I(x; \mathbf{c}) = \sum_{x, \mathbf{c}} p(x, \mathbf{c}) \log \frac{p(x|\mathbf{c})}{p(x)} \quad (4-2)$$

因此本文提出自回归模型 g_{ar} 来进行，如图 4-4 所示，建立卷积神经网络作为特征提取器 g_{enc} 将信号 x_t 转化为特征 z_t ，那么可以使用模型拟合一个密度比来维持公式(4-2)中 x_{t+k} 与 $\mathbf{c}$ 的交互信息：

$$f_k(x_{t+k}, c_t) \propto \frac{p(x_{t+k}|c_t)}{p(x_{t+k})} \quad (4-3)$$

而函数 $f_k(\cdot)$ 则可以使用简单的 log-双线性模型:

$$f_k(x_{t+k}, c_t) = \exp(z_{t+k}^T W_k c_t) \quad (4-4)$$

最终优化损失函数 $InfoNCE$ 就可以同时优化特征提取器 g_{enc} 和自回归模型 g_{ar} :

$$InfoNCE = -\mathbb{E}_X [\log \frac{f_k(x_{t+k}, c_t)}{\sum_{x_j \in X} f_k(x_j, c_t)}] \quad (4-5)$$

训练时通过从 $p(x_{t+k}|c_t)$ 中挑选正样本和 $(N-1)$ 个来自分布 $p(x_{t+k})$ 的负样本进行优化。




图 4-4 保证特征可预测性的对比学习方法

4.2.3 特征降维可视化对比及分析

为了检验所提取特征的有效性, 此处将对所提取特征进行降维可视化, 观察这些提取特征随时间的变化规律。为了更好进行对比, 此处分别对时域信号的特征、基于自编码器的特征提取器所提取特征以及基于对比学习的特征提取器所提取的特征进行比较。其中, 基于对比学习的特征是由以上两种方法所提取的特征组合而成。

另一方面, 考虑到轴承特征随时间变化的分布空间可能不是欧几里得空间二是流形空间, 因此采用 PCA+t-SNE 进行特征降维。其中主成分分析 (principal components analysis, PCA) 是一种有效减少数据维度的线性降维方法, 而 T 分布和随机近邻嵌入 (T-distributed Stochastic Neighbor Embedding, t-SNE) 则可以有效将流行空间中的特征降维而不影响其流形分布的规律。经过降维可视化之后, 可以清晰观察这些特征随时间的变化情况。

以下就以 Bearing1_1 为例子，其三类特征降维可视化如图 4-5 所示，可以清晰得看出，时域特征只能够分开部分轴承健康阶段和退化阶段数据；而基于自编码器方法所提取的特征则圆形分布，健康阶段的特征大多集中在圆心，而退化阶段的特征则集中在圆形边界上，虽然能够分开健康阶段和退化阶段的特征，但丢失了特征变化过程的信息（连续性）；而基于对比学习方法所提取的特征则更加满足我们的需求，不仅能够分开健康阶段和退化阶段，而且保留了足够的特征变化信息。




图 4-5 各类特征降维可视化

4.3 轴承剩余寿命实时预测网络

在第三章中，虽然采用与轴承剩余寿命呈线性关系的轴承健康状态指标作为神经网络的输出，能够成功实现了对超长时间序列的学习和预测。但是这种策略仍然存在缺点，首先，通过建立简单线性的轴承健康状态指标虽然有利于神经网络的学习，但也失去了神经网络端到端解决问题的优势；其次则是当轴承全生命周期非常长的时候，哪怕经过卷积压缩，数据长度仍然会超过神经网络可处理的长度，进而导致预测失败。为此，本节将根据这两点对轴承剩余寿命预测算法进行优化。

4.3.1 端到端的剩余寿命预测

轴承剩余寿命端到端预测首先需要解决两个问题，一是轴承剩余寿命数值过大，容易导致神经网络在反向传递损失时造成梯度爆炸，因此需要一个函数将轴承剩余寿命数值映射到一个较低的范围里。

二是轴承剩余寿命往往不能够准确表示轴承的真实健康状态，原因之一是轴承剩余寿命测量时，由于轴承损坏状态的量化程度不够精准而导致较大的人为测

量误差；其次则是轴承剩余寿命实际上是轴承当前健康状态以及退化趋势的非线性函数。在训练数据量较少（测试轴承数目较少）的情况下，如果贸然使用轴承剩余寿命作为神经网络的理想标签，轴承退化趋势的随机性将会大概率造成神经网络的过拟合现象。即神经网络能够准确学习到训练数据中所出现过的轴承退化趋势并准确预测，但是这些知识并不能够预测其他轴承的退化趋势，从而使神经网络将这些已经学习到的轴承退化趋势规律应用新轴承上时，会预测出错误的剩余寿命。这也是为什么目前轴承剩余寿命预测领域上，最通用且有效的方法依旧是构建轴承健康状态指标，然后通过各种方法进行轴承健康状态指标预测，最后再使用简单函数比如指数函数来拟合轴承健康状态指标的变化趋势，进而将其距离设定阈值的时间视为轴承剩余寿命的原因。

为了缓解以上两个问题给神经网络预测带来的负面影响，本文拟采用对数函数 $\ln(RUL_t + 1)$ 对所标记的轴承剩余寿命进行映射。经过映射之后，轴承剩余寿命值能够从 10^4 数量级映射到 10^1 数量级内。其次，轴承退化曲线虽然具备随机性，但轴承退化曲线变化最大的地方往往是轴承退化阶段的早期。以最常用作轴承健康状态指标的振动信号均方根值（RMS）为例，如图 4-6 所示。因此为了预测的准确性，神经网络对数据的关注重点应该是轴承退化阶段中晚期。




图 4-6 轴承退化早期随机化严重

而由于神经网络在回归问题上一般使用均方差作为损失函数，且目前神经网络进行轴承剩余寿命预测的偏差仍然较大，对于随时间程直线函数的轴承剩余寿命数值来说，神经网络以预测平均绝对偏差最小化为目标，将会导致预测值的相对偏差随时间而变大，最终结果就是在轴承退化早期可能预测相对偏差较小，而

在退化后期时预测结果的相对偏差则会变大，这一效果在实际应用过程中是不能接受的。

若将轴承剩余寿命值用对数函数映射，则可以缓解这一现象。假设预测值与真实值有的绝对偏差平方为 0.16（多次实验中所训练神经网络可达到的最终误差值），则剩余寿命经过对数函数映射以及线性映射到[0,10]范围时的偏差范围如图 4-7 所示。其中红色区间是经过对数函数映射之后的偏差范围，蓝色区间则是经过线性映射的偏差范围。




图 4-7 使用对数函数映射之后可以降低预测剩余寿命的误差

从图中可以清楚看出对剩余寿命数值进行对数映射之后，在神经网络优化平均误差平方的情况下，使用线性函数映射在前期预测值误差允许范围较低，但当轴承接近损坏，剩余寿命接近于 0 时，可能会导致预测结果在关键时刻因预测相对误差较大，并造成损失。而使用对数函数映射之后，所允许的绝对误差范围会越来越小，从而保证预测结果在关键时刻的可靠性。

4.3.2 特征抽取顺序及位置编码

在第二章中介绍轴承退化规律时已经提及，轴承全生命周期中几乎约 90%处于健康阶段，而退化阶段和损坏阶段所占的时间比例非常少。但是当轴承处于健康状态时，轴承健康状态变化及其微弱。而在根据轴承全生命周期信号进行轴承剩余寿命预测时，却往往会考虑了过多的轴承健康状态信息，导致计算能力的浪费。如果能够减少这部分的冗余信息，使循环神经网络需要处理的序列信息缩短，那么所需要的运算时间将会有效减少。

因此本文提出对于输入进来的一段长时间的轴承振动信号，可以采用对最新的信号进行密集抽取，而对久远的信号进行稀疏抽取的信息抽取方式，如图 4-8

所示，保证在采集较少数据的情况下，算法仍然能够拟合出输入数据随时间的发展趋势。




图 4-8 理想的信号抽取方式

而当对前后数据的抽取间隔不一样时，抽取后的数据会丢失时间信息，不利轴承剩余寿命的预测。为此，需要人为地为数据添加时间信息。本文使用 Vaswani^[82]所提出的位置编码（position encoding）方法，为抽取的数据提供时间信息。设 t 时刻的编码为 $P_t \in R^D$ ，位置编码 $P_t = [P_{t,0}, \dots, P_{t,D-1}]^T$ 如可由公式(4-6)和(4-7)所求的。

$$P_{t,2i} = \sin\left(\frac{t}{10000^{2i/D}}\right) \quad (4-6)$$

$$P_{t,2i+1} = \cos\left(\frac{t}{10000^{2i/D}}\right) \quad (4-7)$$

通过使用三角函数进行编码，可以让网络了解数据之间的相对位置，因为从数学上看， P_t 和 P_{t+k} 在给定 k 的情况下是线性关系，推导过程如以下公式所示。

$$\sin(t+k) = \sin(t)\cos(k) + \sin(k)\cos(t) \quad (4-8)$$

$$\cos(t+k) = \cos(t)\cos(k) - \sin(k)\sin(t) \quad (4-9)$$

$$P_{t+k,2i} = P_{t,2i}P_{k,2i+1} + P_{t,2i+1}P_{k,2i} \quad (4-10)$$

$$P_{t+k,2i+1} = P_{t,2i+1}P_{k,2i+1} - P_{t,2i}P_{k,2i} \quad (4-11)$$

从而可以将不超过 10000 的时间信息压缩为一个数值范围在 $[-1,1]$ 的向量，并入到特征向量中。

而考虑到实际使用过程中，轴承振动信号逐个进入，然后对其进行特征提取，其中振动信号保存到数据库中，而提取特征则保留在运存中进行进一步处理。经过长时间后，特征逐渐累积，然后通过逐步抛弃之前的部分特征，从而实现尾部特征密集抽取，头部特征稀疏抽取，具体过程如图 4-9 所示。




图 4-9 实际使用过程中特征值保留方法

如图 4-9 所示, 本文将抽取间隔设置为 2^i 的形式, 综合考虑轴承退化时间以及神经网络的处理能力, 特征抽取间隔分别为 1, 2, 4, 8, 16, 32, 64, 每段抽取 n 个特征值。特征的具体留弃流程如图 4-10 所示, 分别建立 7 个存放空间, 每个存放空间中包含一个队列型数据类型, 以及一个布尔变量。其中队列型数据只能通过两种操作进行其中数据增删, 分别是压入: 从队列尾部添加数据; 以及抛出: 将队列头部数据抛出。而布尔变量的初始值为真。




图 4-10 实际使用过程中提取特征的存储流程图

当要取出数据进行剩余寿命预测时，则依次读取 7 个队列的数据，合并到一起，再输入到神经网络当中，考虑实际情况，本文选取 $n = 16$ ，因此最长的时间序列长度为 102，且可对应实际长度最长为 2152。

4.3.3 regLSTM 网络

神经网络结构相比于传统机器学习的优点在于能够有效地从大量数据中学习到的数据中更加复杂抽象的特征信息，从而在处理大量复杂数据时具备与人类相近甚至超过人类的效果^[83]。在数据足够丰富的情况下，研究人员提出日益复杂的神经网络模型企图学习更加复杂的特征信息，取得更好的处理效果。比如从注意力机制进一步演化的 transformer 模型^[82]。

然而复杂的模型往往意味着更难训练，且最终效果对模型超参数更加敏感^[84]，最重要的是更加复杂的模型需要更多的计算能力，即运行时需要更多的运行空间以及运算时间，这对于实时性是不利的。

为了提高轴承剩余寿命预测的实时性，本文使用添加正则化限制的 LSTM 网络模型（regLSTM）进行轴承剩余寿命预测。改网络模型结构如图 4-11 所示。




图 4-11 regLSTM 网络结构

主体主要由一个单层双向 LSTM 网络以及一个两层的全连接网络所组成，经过抽取之后的特征序列经过双向 LSTM 网络之后，可以得到时间维度上相等，特征维度尺寸为 LSTM 隐藏神经元数量的特征输入，然后对时间维度进行最大值池化，得到最终的输出特征向量，最后经过两层的全连接网络预测轴承剩余寿命。

而在训练过程中，主要通过两种正则化限制来确保网络不出现过拟合现象，从而保证该模型的预测效果。这两种正则化限制分别是 Embedding Dropout 以及在 LSTM 网络的全连接矩阵中使用 weight-dropped。

Embedding Dropout 是 Gal 等人^[85]提出的正则化策略,首次应用在自然语言处理上,其核心思想是对于一段有序的时间序列来说,其整体特征是由所有的数据所组成的,而不会因为缺失部分数据而发生巨大改变,因此对于一个具备足够强学习能力的 LSTM 网络来说,应该具备从一段缺失部分数据的时间序列中学习正确的特征的能力。而具体实施时则是通过对训练的时间序列随机将部分数据置零表示该数据缺失,并让 LSTM 网络拟合理想输出,最终提高 LSTM 网络的特征提取能力。

Weight-dropped LSTM 网络结构则是由 Merity 等^[86]提出的,从公式(2-30)-(2-34)中可以看出 LSTM 网络中总共有 8 个矩阵分别连接输入层到隐藏层以及不同时刻之间的隐藏层的神经元,而在 weight-dropped LSTM 网络中,则是在训练过程中对连接不同时刻隐藏层的矩阵连接中进行 DropConnect 操作^[87],通过提高 LSTM 网络获取历史信息的难度来提高 LSTM 的泛化能力。

4.4 预测结果

最终预测结果如图 4-12 所示,虽然相比于上一章中提出的剩余寿命预测算法准确率有所下降,但该算法在测试集数据中仍然有较好的预测效果。

图 4-12 中,预测剩余寿命用散点图来表示,其中预测剩余寿命与真实剩余寿命的相对误差绝对值小于 0.2 的以绿色散点表示,表示该预测结果的误差是令人满意的;而相对误差绝对值小于 0.5,大于等于 0.2 的则以黄色散点表示,表示该预测结果的误差是可以接受的;而相对误差绝对值大于等于 0.5 的则以红色散点表示,表示该预测结果的误差是不能够接受的。从图中结果可以看出,该算法在 PHM2012 测试数据集中最后一部分的预测结果基本处于黄色和绿色区间,表明预测的相对误差绝对值都小于 0.5,相比于表 3-2 中各种剩余寿命预测算法的平均相对误差绝对值也是一个不错的结果。尤其是当轴承在正常运转时间较长的数据中,如 Bearing1_5、Bearing1_6、Bearing2_5 中,所预测的剩余寿命值在接近数据末尾(退化阶段早期到中期)基本都是绿色散点,表明预测结果比较准确。同时,为了进一步量化预测剩余寿命的相对误差,分别计算出各测试轴承在最后 5%,10%,15%,20%,25%以及 30%时间段里的平均相对误差绝对值,如表 4-1 所示。




图 4-12 实时预测算法预测结果与真实剩余寿命对比

表 4-1 滚动轴承实时剩余寿命预测算法在 PHM2012 测试数据中平均相对误差绝对值

	最后 5%	最后 10%	最后 15%	最后 20%	最后 25%	最后 30%
Bearing1_3	32.57%	28.26%	26.01%	28.95%	36.76%	41.74%
Bearing1_4	56.23%	110.48%	124.58%	110.32%	100.56%	95.83%
Bearing1_5	23.72%	27.58%	24.83%	30.65%	37.89%	44.87%
Bearing1_6	25.59%	36.02%	31.35%	28.06%	29.71%	28.62%
Bearing1_7	34.91%	36.19%	42.21%	46.17%	45.97%	47.47%
Bearing2_3	37.70%	36.97%	38.91%	39.19%	39.34%	46.50%
Bearing2_4	54.36%	30.95%	24.92%	35.58%	45.73%	50.98%
Bearing2_5	30.61%	19.21%	15.50%	25.73%	35.87%	42.60%
Bearing2_6	66.58%	48.39%	46.98%	46.15%	48.41%	52.01%
Bearing2_7	59.37%	68.19%	77.51%	77.49%	70.94%	62.07%
Bearing3_3	47.61%	44.37%	44.58%	45.99%	46.62%	49.05%
平均值	42.66%	44.24%	45.22%	46.75%	48.89%	51.07%

为检测该算法的实时性能，将根据实际情况测试该算法的运行时间。其中该算法包括 2 个特征提取器以及 1 个 LSTM 网络进行剩余寿命预测，因此在每段振动信号进来之后，分别进行两次特征提取，然后将该特征更新到特征存储空间中，然后再使用 LSTM 进行预测，若仅考虑神经网络的运行时间的话需要将该 3 个网络的运行时间进行相加。其中两个特征提取器的网络结构及参数数量是相同的，因此所需要的处理时间也是相同的，而 LSTM 的所需要的处理时间与输入序列的长度有关，为了测试极端情况下的运行时间，选择一段特征存储空间存满时的数据，即长度为 102 的特征序列测试结果如表 4-2 所示：

表 4-2 神经网络运行单个数据所需时间（s）

网络	首次运行	后续运行
特征提取器	0.2	0.002
LSTM	0.24	0.04

可以看出神经网络首次运行与之后运行的速度差别较大，而在进行实时监测时，实际运行时间与后续运行时间相近，因此对应每一个输入数据，神经网络的运行时间大约为 $0.002 \times 2 + 0.04 = 0.044s$ ，满足实时性需求。

4.5 本章小结

为实现轴承剩余寿命预测的实时性，本章提出使用基于对比学习的特征提取网络进行轴承振动信号的特征提取，且其提取特征在降维可视化上显示出比传统使用的轴承时域统计特征能够更加清晰分开轴承健康阶段和退化阶段数据的能力，并且更好保留了轴承状态随时间变化的信息。然后提出使用简单的 LSTM 网络对部分抽取特征进行剩余寿命预测，从而大大减少了以往使用循环神经网络时的运行时间，达到了 0.04 秒，总用时达到 0.044 秒，在预测结果准确率下降较低的情况下，大幅提高了轴承剩余寿命预测算法的实时性。

第5章 滚动轴承实时监测软件设计及开发

5.1 引言

将轴承剩余寿命智能预测算法应用到实际设备上需要能够搭载它的实时监测软件，本章使用 C#语言开发轴承剩余寿命监测系统。具体功能包括数据采集，数据读写，数据处理以及结果可视化等功能。

5.2 软件功能需求

如图 5-1 所示，根据软件功能需求，可以将软件划分为 5 个功能模块，分别是：

- 1) 数据采集模块，调用信号采集卡提供的 API 接口，设置信号采集卡各项采集参数，并从信号采集卡上获取所采集的数字信号。
- 2) 数据库模块，有效率地实现大量数据的增删改查功能。
- 3) 数据处理模块，对需要处理的信号进行快速的数据处理，包括简单的快速傅里叶变换，滤波以及本文所建立的神经网络模型。
- 4) 数据可视化模块，包括对原始数据、处理后的数据可视化功能，并具备一定的人机交互功能，从而使用者可对数据进行多方面观察。
- 5) 警报管理模块，当算法预测出来的轴承剩余寿命较低时，及时弹出警报，并记录。




图 5-1 监测软件功能划分图

5.3 软件体系框架

监测软件的整体体系框架如图 5-2 所示，其中数据仓库和采集卡配置信息存放在硬盘上，通过数据访问接口进行数据访问管理。人机交互界面中显示内容包括数据可视化的图表、警报显示以及具体参数设置窗口。软件内部（业务服务）则统一管理并进行这些操作。此外，为了方便监测软件后续开发及更新，在显示功能、信号处理方法和采集卡管理功能上使用模块化开发的模式。比如快速傅里叶变换和信号滤波同属于信号处理功能，在编写这两种类时，可以使其满足信号处理方法的接口，从而能够快速开发多种信号处理功能，且修改其中代码不会对软件其他功能造成影响。




图 5-2 软件体系框架图

5.4 软件各功能具体设计及开发

5.4.1 数据采集

信号采集卡是将传感器所采集的模拟电信号转换为数字信号并传输到计算机的硬件设备，需要有对应的软件才能进行。信号采集卡厂商一般带有专用的使用软件，同时也提供可用于二次开发的各种语言 API，以满足设计人员需要。

该监测软件应不依赖于某个信号采集卡，因此需要设计对应的信号采集卡管理接口，各类采集卡只需要根据该接口进行二次开发即可使用。该接口具备如图 5-3 所示的功能。获取部分包括采集卡名称、采集卡通道数目及名称、采集卡最高采样频率、采集卡允许采集的电信号范围，以及获取采集的数字信号；而设置部

分包括设置采集信号通道、设置电信号范围、设置采样频率等等，并且该类设置参数应存储在硬盘上，从而在软件下次打开时不需要重新设置。具体设置页面如图 5-4 所示。




图 5-3 采集卡接口需满足的工作内容



(a)采集卡设置总表

(b)采集卡属性设置

图 5-4 采集卡设置界面

5.4.2 数据存储及管理

在信号处理过程中，一些信号的采集信息，比如采样频率，也是比较重要的。为了方便存储采集信号及相关信息，采用关系式数据库进行数据管理。综合考虑各类数据库的运行性能以及硬件设备，该软件使用 SQLite 对数据进行表格化存储和管理。

由于机电系统中所监测数据类型繁多，同时监测的信号通道较多，为方便对各路信号数据进行存储及管理，存储形式如图 5-5 所示，存储的表格分为母表和子表。母表中记录各项采集信号的采集参数，包括数据采集卡名字（型号）、信号命名、所检测的设备、传感器安放位置、信号分辨率、传感器类型、电信号范围；而目标上每一行数据则对应一个子表，子表以该采集信号名称命名，主要记录采集的信号，包括采集时间以及电信号值。

在针对轴承剩余寿命预测问题上，该软件所采集并存储的信号以振动信号为主，而振动信号的采样频率一般较高，从 10^3Hz 到 10^5Hz 不等，长时间的高频信号其数据量之大，必然会造成极大的存储空间压力，因此在该软件对数据存储过程中，进行一些必要处理减少存储压力。其中，由于所采集信号一般是等时间间隔的，所以可以只记录采集信号的首尾时间，减少存储压力；其次，从信号采集卡上获取的数字信号可使用二进制形式，并进行存储，由于目前常用的采集卡的模数转换精度不大于 16 位，是计算机浮点数存储空间 64 位的四分之一，可以极大地减少所需要的存储空间。

同样的，在对数据进行操作（增删改查）时，也是按顺序分别对母表和对应的子表进行操作，具体流程简图如图 5-6 所示。




图 5-5 软件数据库中母表与子表的连接




图 5-6 数据管理流程简图

5.4.3 数据处理

针对轴承健康状态的实时监测，该软件对轴承振动信号的处理方法包括信号滤波、快速傅里叶变换、短时傅里叶变换以及剩余寿命预测。

其中信号滤波包括一些简单的数字信号滤波方法，比如均值滤波等，可有效地消除一些比较明显的噪声，对信号进行一定程度的提纯，如图 5-7 所示。




图 5-7 原始振动信号及滤波后的振动信号

而快速傅里叶变换是获得数字信号频谱信号的工具，而且从振动信号的频谱图中可以实时标记并监测轴承的故障频率，一方面可以从多方面对轴承健康状态进行评估，另一方面可以观测轴承退化时的故障特征频率变化，如图 5-8 所示。




图 5-8 振动信号频谱图及轴承故障特征频率标志线

在短时傅里叶变换的时频图中，可以比较明显地观测轴承的一些特征频率随时间变化的趋势，比如轴承的转速频率，如图 5-9 所示。




图 5-9 轴承转速提升时时频图

最后则是轴承剩余寿命智能预测算法，通过 TensorFlow.net 库可以方便快捷的在 .net 框架中添加基于 TensorFlow 框架的神经网络模型，从而简单实现在软件中对神经网络进行训练以及使用。

5.4.4 警报模块

警报模块可以在预测到轴承剩余寿命较低时给使用者发出提示，从而避免轴承损坏造成损失。因此警报模块需要设置在最突出的位置。

此外，对警报事故进行记录，可以有效地提醒操作者，记录内容包括警报发出时间、警报原因、警报严重性以及可能的解决办法，如图 5-10 所示。并且可以将记录整合为一个专家字典，方便后续操作人员进行警报排除工作。

时间	严重程度	可能原因	可能解决措施	筛选
2020年06月10日 18:02:21	提示	未检测到数据采集卡	请检测数据采集卡是否正确接入并...	☒ 提示
2020年06月10日 19:36:00	提示	未检测到数据采集卡	请检测数据采集卡是否正确接入并...	☒ 一般
				☒ 严重
				清空所有

图 5-10 警报管理栏

5.4.5 界面设计

软件的界面如图 5-11 所示，其中按布局可分为主窗口以及下侧、左侧的副窗口，主窗口中有三个页面可以切换。分别是轴承状态监测及剩余寿命预测页面，进行采集数据设置的页面，以及帮助的页面。左侧的副窗口为菜单栏，可以进行切换主窗口页面，而下侧的副窗口则是显示各类警报信息。其中监测的主页面中，显示部分可分为 6 个部分，监测信息主要是轴承竖直方向（z 轴）以及水平方向（x 轴）的振动信号，振动信号采集回来之后会以根据振动信号的峰峰值在显示框①中的传感器图像上显示不同的颜色，以方便监测人员对监测轴承的振动进行直观的观察；其次，振动信号也会在显示框②的图表中实时显示，若选择了滤波器，则会显示滤波之后的振动信号；接下来，这两段振动信号将进行快速傅里叶变换以及短时傅里叶变换，分别以频谱图和时频图的形式显示在显示框③和④中，方便监测人员对振动信号进行频域的观察以及分析其变化。




图 5-11 软件主要操作界面

而显示框⑤和⑥则分别显示轴承振动信号的 RMS 特征值以及所预测的轴承剩余寿命（RUL），通过综合分析这两个指标给出比较准确的轴承状态。采取这样的措施的主要原因是，从第四章所提出的轴承剩余寿命实时预测算法的预测结果可以看出，该算法在轴承处于健康阶段时，所预测的剩余寿命并不具备太大的参考意义，所以在实际使用过程中，将根据轴承振动信号的 RMS 特征进行轴承是否处于退化甚至损坏阶段的判断，其判断依据是根据将来的 RMS 值是否在之前记录的

RMS 值所拟合的正态分布的 3σ 范围内, 若 RMS 值在该范围内, 且剩余寿命预测结果较高 ($RUL > 50$), 则认为轴承处于安全阶段, 不触发任何警报; 若 RMS 超出该范围, 且剩余寿命预测结果较低 ($RUL \leq 50$), 且预测结果维持比较平稳的斜率, 则触发警报, 通过弹窗的方式提醒监测人员密切注意轴承状态; 当 RMS 多次超出该允许范围, 且剩余寿命预测结果非常低 ($RUL \leq 10$) 时, 将通过弹窗的方式建议监测人员停止设备运转。

5.4.6 软件开发及维护

为便于软件的快速开发和维护, 对该软件进行模块化开发, 如图 5-12 所示。




图 5-12 软件各模块

根据功能不同, 分别有:

- a 采集卡模块: 采集卡接口以及针对目前使用的各类型号采集卡所开发的程序;
- b 表格显示及处理: 可统一对图表进行显示以及交互处理;
- c 数据库模块: 数据库的增删改查功能;
- d 数据压缩模块: 管理数据压缩算法, 方便更新或更换合适的数据压缩算法;
- e 数据输出模块: 对应各种数据输出格式, 目前支持 txt、csv 以及 mat 格式的数据输出;
- f 警报管理模块: 警报管理, 包括预警程度、危害程度、可能的解决措施等, 甚至可以添加专家知识库;

g 设置窗口：软件在许多地方需要加入设置窗口进行各项参数设置，比如采集卡设置、数据处理方法中的参数设置等等，而这些设置往往也需要有高度的可定制性；

h 数据处理：管理数据处理接口以及各种数据处理方法，包括数字滤波、傅里叶变换以及神经网络算法等。

5.5 软件实际使用流程

在软件打开的时候，会根据满足采集卡接口的程序，自动检测计算机是否已经插入对应的数据采集卡，若检测不到采集卡，则弹窗提示，并将该错误添加到警报管理栏目中，并且禁止对该采集卡进行参数设置等操作。

若软件在该计算机上首次启动后，应添加各个采集信号，并设置对应采集卡的参数，然后进行保存。这些设置参数将会在本地产生产 CardSetting.dat 文件，而当再次打开软件时，则会自动加载这些设置参数。

各个采集信号设置完毕之后，则可以开始对各路采集信号在右侧副窗口处进行监测。并且可以开启实时的数据处理功能，如数字滤波、快速傅里叶变换、短时傅里叶变换以及轴承剩余寿命预测。这些结果都可以在主窗口中切换页面进行查询。

5.6 本章小结

为了实现轴承剩余寿命实时监测能够实际应用，本章使用 C# 开发轴承实时监测软件。根据软件的具体功能需求，即数据采集、数据分析以及数据存贮，分析软件整体框架，对软件按功能进行模块化开发，使软件能够适用于各类信号采集卡，而且软件中的数据处理算法、数据压缩算法以及数据显示、数据导出格式都有极高的可扩展性，为以后的智能算法，尤其是神经网络算法在实际设备上的应用提供充足的软件支持。

结 论

滚动轴承对旋转机械设备的良好运行起着关键性的作用，对滚动轴承实现实时性剩余寿命预测可以在保证滚动轴承的稳定性前提下有效提高滚动轴承的服役时间。文本以滚动球轴承为研究对象，研究滚动轴承退化规律，利用大数据和深度学习的优势，提出了准确有效的基于注意力机制的滚动轴承剩余寿命预测神经网络结构。然后根据实时性要求，提出使用神经网络对轴承振动信号进行更有效的特征提取，然后使用简单 regLSTM 网络利用少量数据实现滚动轴承剩余寿命快速预测功能，保证实时性要求。

本文主要研究工作及成果总结如下：

(1) 提出用于滚动轴承剩余寿命预测的基于注意力机制的循环神经网络结构。通过卷积压缩以及注意力机制，有效解决了滚动轴承全生命周期特征序列长度过长而导致网络训练失败的问题，并利用大数据的优势，提高了滚动轴承剩余寿命预测的准确性。

(2) 针对滚动轴承剩余寿命预测过程中，常用的轴承振动信号特征提取方法效果不佳的问题，提出使用基于对比学习的深度网络，成功提取出更能体现轴承健康状态的特征值。

(3) 利用更加有效的轴承振动信号特征信息，提出通过对历史特征的进行部分抽取，以及简单的 regLSTM 网络对轴承剩余寿命进行预测。最终在测试数据集上的测试结果表明，该方法在保证预测准确率的情况下，大幅度提高了预测速度，仅用 0.044 秒，达到实时性需求。

(4) 使用 C#语言编写模块化的滚动轴承剩余寿命实时监测及预测的软件。通过模块化和接口化设计，让软件摆脱了对特定数据采集卡的依赖，并实现信号处理算法的快速开发以及更新迭代，并使用 Tensorflow.net 模块快速嵌入基于 TensorFlow 框架的深度学习模型，为以后基于深度学习算法在实际工程的使用打下软件基础。最后利用数据集的振动信号模拟信号输入，在软件上实现轴承状态实时监测及剩余寿命预测。

虽然一直有研究者对轴承剩余寿命预测进行研究，但其实用化、工业化的进展仍需要大量研究者的共同努力。针对深度学习在轴承剩余寿命预测的问题，以后拟从以下几个方面展开后续研究：

(1) 通过不同设备、不同尺寸轴承数据融合，提高神经网络对轴承退化特征的抗噪能力。由于轴承振动信号测量方法的缘故，轴承振动信号中往往参杂着大

量有关机械设备及环境的信息，使用深度学习这一黑箱子对单一情况的轴承振动信号进行处理难以确保这些噪声的去除程度，唯有提高数据的丰富程度才能让神经网络进一步提纯轴承状态信息。

（2）通过结合轴承退化物理模型与数据分析方法进一步分析轴承退化机理。发展至今，轴承种类及型号愈加繁杂，且其工作环境也各不一致，仅仅依靠少量从实验室所测得的实验数据不足以支撑通用性的轴承剩余寿命预测方法的出现，唯有结合轴承退化物理模型与深度数据分析方法，才可以对轴承退化机理进行更加详细的研究并实现精准量化，进而提高轴承剩余寿命预测的准确性。

参考文献

- [1] 张翔,赵群.大数据时代中国制造业创新发展试述[J].机械制造,2015,53(08):1-5.
- [2] 中国科学技术协会. 2014~2015 机械工程学科(摩擦学)发展研究报告[M]. 中国科学技术出版社, 2016.
- [3] 刘颀. 基于振动信号分析的旋转机械故障诊断方法研究[D].华中科技大学,2018.
- [4] 牛乾. 机械旋转部件的性能退化及其寿命预测方法研究[D].浙江大学,2018.
- [5] 鞠萍华. 旋转机械早期故障特征提取的时频分析方法研究[D].重庆大学,2010.
- [6] 黄伟国. 基于振动信号特征提取与表达的旋转机械状态监测与故障诊断研究[D].中国科学技术大学,2010.
- [7] 李扬. 基于混沌理论的滚动轴承故障诊断及故障趋势预测研究[D].西南交通大学,2018.
- [8] 蒋杰. 基于轨旁声学信号的城轨列车滚动轴承故障诊断研究[D].南京理工大学,2017.
- [9] 王晓龙. 基于振动信号处理的滚动轴承故障诊断方法研究[D].华北电力大学(北京),2017.
- [10] 胡龙飞. 基于深度学习的滚动轴承寿命预测[D].西南交通大学,2019.
- [11] 王德海. 风力发电机组故障在线诊断技术的研究[D].吉林大学,2018.
- [12] 杨圆鉴. 基于退化模型的机械产品可靠性评估方法研究[D].电子科技大学,2016.
- [13] 黄承赓. 基于监测大数据的产品剩余寿命预测方法研究[D].电子科技大学,2019.
- [14] 刘颀. 基于振动信号分析的旋转机械故障诊断方法研究[D].华中科技大学,2018.
- [15] 张小丽, 王保健, 马猛,等. 滚动轴承寿命预测综述%A Review of Life Prediction for Roller Bearing[J]. 机械设计与制造, 2015, 000(010):221-224.
- [16] P. C. Paris, F. Erdogan. A critical analysis of crack propagation laws[J]. Journal of Basic Engineering, 1963, 85(4):528-533
- [17] Ioannides E , Harris T A . A New Fatigue Life Model for Rolling Bearings[J]. Journal of Tribology, 1985, 107(3):367-377.

- [18]李旭东,张仕朝,刘祎.滚动接触疲劳寿命预测方法综述[J].航空精密制造技术,2017,53(03):1-4.
- [19]范磊,王少萍,张超,孔德贺,毛阳.直升机行星架疲劳裂纹扩展寿命预测[J].北京航空航天大学学报,2016,42(09):1927-1935.
- [20]Qiu H , Lee J , Lin J , et al. Robust performance degradation assessment methods for enhanced rolling element bearing prognostics[J]. Advanced engineering informatics, 2003, 17(3/4):p.127-140.
- [21]申中杰,陈雪峰,何正嘉,孙闯,张小丽,刘治汶.基于相对特征和多变量支持向量机的滚动轴承剩余寿命预测[J].机械工程学报,2013,49(02):183-189.
- [22]Ben Ali, Jaouher,Chebel-Morello, Brigitte,Saidi, Lotfi, et al. Accurate bearing remaining useful life prediction based on Weibull distribution and artificial neural network[J].Mechanical Systems & Signal Processing,2015,56/57:150-172.
- [23]张亢,程军圣,杨宇.基于局部均值分解与形态学分形维数的滚动轴承故障诊断方法[J].振动与冲击,2013,32(09):90-94.
- [24]Qian Y , Yan R , Gao R X . A multi-time scale approach to remaining useful life prediction in rolling bearing[J]. Mechanical Systems and Signal Processing, 2016:S0888327016302138.
- [25]Cadini F , Zio E , Avram D . Monte Carlo-based filtering for fatigue crack growth estimation[J]. Probabil engineering mechanics, 2009, 24(3):367-373.
- [26]Zio E , Peloni G . Particle filtering prognostic estimation of the remaining useful life of nonlinear components[J]. Reliability Engineering & System Safety, 2011, 96(3):p.403-409.
- [27]Li Y , Billington S , Zhang C , et al. Adaptive prognostics for rolling element bearing condition[J]. mechanical systems & signal processing, 1999, 13(1):103-113.
- [28]Lei Y , Li N , Gontarz S , et al. A Model-Based Method for Remaining Useful Life Prediction of Machinery[J]. IEEE Transactions on Reliability, 2016, 65(3):1314-1326.
- [29]杨洋. 基于遗传算法优化支持向量机的风电机组齿轮箱剩余寿命预测研究[D]. 吉林大学,2017.
- [30]于震梁,孙志礼,曹汝男,王鹏.基于支持向量机和卡尔曼滤波的机械零件剩余寿命预测模型研究[J].兵工学报,2018,39(05):991-997.

- [31]García Nieto, P.J, García-Gonzalo, E, Sánchez Lasheras, F, et al. Hybrid PSO-SVM-based method for forecasting of the remaining useful life for aircraft engines and evaluation of its reliability[J]. Reliability Engineering & System Safety, 2015, 138(jun.):219-231.
- [32]Pan W T . A new Fruit Fly Optimization Algorithm: Taking the financial distress model as an example[J]. Knowledge Based Systems, 2012, 26:p.69-74.
- [33]孙在东. 基于 HMM 时间序列分析的列车轴承健康监测的研究[D].北京交通大学,2019.
- [34]CAREY, BUNKS, et al. CONDITION-BASED MAINTENANCE OF MACHINES USING HIDDEN MARKOV MODELS[J]. Mechanical Systems & Signal Processing, 2000.
- [35]Baruah P, Chinnam R B. HMMs for diagnostics and prognostics in machining processes[J]. International Journal of Production Research, 2005, 43(6): 1275-1293.
- [36]周建民,张臣臣,张龙,郭慧娟.基于融合模糊 C 均值与隐马尔科夫模型的滚动轴承的退化状态识别[J].机械设计与研究,2019,35(03):83-86.
- [37]张旺,陈磊,陈超宇,韩捷.Hilbert-全矢 HMM 轴承剩余寿命预测[J].机械设计与制造,2020(03):95-98.
- [38]Gebraeel N , Lawley M , Liu R , et al. Residual life predictions from vibration-based degradation signals: a neural network approach[J]. IEEE Transactions on Industrial Electronics, 2004, 51(3):694-700.
- [39]Guo L , Li N , Jia F , et al. A recurrent neural network based health indicator for remaining useful life prediction of bearings[J]. Neurocomputing, 2017, 240(May31):98-109.
- [40]Chen Z , Liu Y , Liu S . Mechanical state prediction based on LSTM neural network[C]// 2017 36th Chinese Control Conference (CCC). 2017.
- [41]Huang R , Xi L , Li X , et al. Residual life predictions for ball bearings based on self-organizing map and back propagation neural network methods[J]. Mechanical systems and signal processing, 2007, 21(1):p.193-207.
- [42]Babu G S , Zhao P , Li X L . Deep Convolutional Neural Network Based Regression Approach for Estimation of Remaining Useful Life[J]. 2016.
- [43]Ren L , Sun Y , Cui J , et al. Bearing remaining useful life prediction based on deep autoencoder and deep neural networks[J]. Journal of Manufacturing Systems, 2018:S0278612518300475.

- [44]任利娟. 滚动轴承性能退化评估与剩余寿命预测[D].山东大学,2019.
- [45]张肖曼. 基于 BP 神经网络的机车走行部滚动轴承的故障诊断研究[D].北京交通大学,2013.
- [46]梁华,郭浩,王煜哲.滚动轴承接触疲劳失效的分析方法[J].轴承,2015(09):26-29.
- [47]顾超. 高品质轴承钢疲劳寿命预测模型及夹杂物影响规律研究[D].北京科技大学,2019.
- [48]曾宇. 滚动轴承多域退化表征指标提取及寿命预测研究[D].北京交通大学,2019.
- [49]Nectoux P , Gouriveau R , Medjaher K , et al. PRONOSTIA: An experimental platform for bearings accelerated degradation tests[C]// IEEE International Conference on Prognostics and Health Management. IEEE, 2012.
- [50]陈晓梅,王会强,翟一潼,邢艳秋,张淼,孙维连,郝策,王浩伟,柯稳.GCr15SiMn 滚动轴承钢的磨损失效分析 [J/OL]. 热加工工艺:1-5[2020-05-15].<https://doi.org/10.14158/j.cnki.1001-3814.20183162>.
- [51]潘玉娜. 滚动轴承的性能退化特征提取及评估方法研究[D].上海交通大学,2011.
- [52]王明华. 滚动轴承退化状态识别技术研究[D].沈阳理工大学,2015.
- [53]刘晓飞. 基于 LSTM 网络的滚动轴承可靠性评估及寿命预测[D].大连理工大学,2019.
- [54]Huang N E . New method for nonlinear and nonstationary time series analysis: empirical mode decomposition and Hilbert spectral analysis[J]. Proceedings of Spie the International Society for Optical Engineering, 2000, 4056:197-209.
- [55]邱翔. 分层流动中湍流结构和湍流逆梯度输运特性研究[D].上海大学,2006.
- [56]谢阶栋. 基于损伤力学的滚动轴承疲劳寿命预测[D].南京航空航天大学,2018.
- [57]Lecun Y , Bottou L . Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11):P.2278-2324.
- [58]Szegedy C , Ioffe S , Vanhoucke V , et al. Inception-v4, Inception-ResNet and the Impact of Residual Connections on Learning[J]. 2016.
- [59]Cho K , Van Merriënboer B , Gulcehre C , et al. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation[J]. Computer Science, 2014.

- [60]Jun Z , Nan C , Weiwen P . Estimation of Bearing Remaining Useful Life based on Multiscale Convolutional Neural Network[J]. IEEE Transactions on Industrial Electronics, 2018:1-1.
- [61]Ian Goodfellow, Yoshua Bengio, Aaron Courville. Deep Learning[M]. The MIT Press, 2016.
- [62]Hornik K , Stinchcombe M , White H . Multilayer feedforward networks are universal approximators[J]. Neural Networks, 1989, 2(5):359-366.
- [63]Janssens O, Slavkovikj V, Vervisch B, et al. Convolutional neural network based fault detection for rotating machinery [J]. Journal of Sound and Vibration, 2016, 377: 331-345.
- [64]Zhang W , Li C , Peng G , et al. A deep convolutional neural network with new training methods for bearing fault diagnosis under noisy environment and different working load[J]. Mechanical systems and signal processing, 2018, 100(FEB.1):439-453.
- [65]Rumelhart D E , Hinton G E , Williams R J . Learning representations by back-propagating errors[J]. nature, 1986, 323(6088):533-536.
- [66]Bengio Y . Learning Long-term Dependencies With Gradient Descent is Difficult[J]. IEEE Transactions on Neural Networks, 1994, 5.
- [67]Graves A . Long Short-Term Memory[J]. 2012.
- [68]Henaff M , Szlam A , Lecun Y . Recurrent Orthogonal Networks and Long-Memory Tasks[J]. 2016.
- [69]Malhi, A.,Yan, R.,Gao, R. X. Prognosis of Defect Propagation Based on Recurrent Neural Networks[J]. Instrumentation & Measurement IEEE Transactions on, 2011, 60(3):p.703-711.
- [70]Cho K , Van Merriënboer B , Gulcehre C , et al. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation[J]. Computer Science, 2014.
- [71]Luong M T , Pham H , Manning C D . Effective Approaches to Attention-based Neural Machine Translation[J]. Computer Science, 2015.
- [72]Sutrisno, Edwin, Oh, Hyunseok, Vasan, Arvind Sai Sarathi,等. Estimation of remaining useful life of ball bearings using data driven methodologies[M]. 2012.

- [73]Hinchi A Z , Tkouat M . Rolling element bearing remaining useful life estimation based on a convolutional long-short-term memory network[J]. Procedia Computer Science, 2018, 127:123-132.
- [74]Hong S , Zhou Z , Zio E , et al. Condition assessment for the performance degradation of bearing based on a combinatorial feature extraction method[J]. Digital Signal Processing, 2014, 27:159-166.
- [75]曾柯. 基于SPSO优化TWSVM及Bayesian更新指数模型的轴承剩余寿命预测[D].重庆大学,2018.
- [76]者娜. 基于大数据技术的滚动轴承故障诊断及剩余寿命预测方法研究[D].北京化工大学,2018.
- [77]Kingma D P , Welling M . Auto-Encoding Variational Bayes[C]// ICLR. arXiv.org, 2014.
- [78]Jakab T . Unsupervised Learning of Object Landmarks through Conditional Image Generation[J]. 2018.
- [79]Sermanet P , Lynch C , Chebotar Y , et al. Time-Contrastive Networks: Self-Supervised Learning from Video[J]. 2017.
- [80]Misra M , Yue H H , Qin S J , et al. Multivariate Process Monitoring and Fault Diagnosis by Multi-Scale PCA[J]. Computers & Chemical Engineering, 2002, 26(9):1281-1293.
- [81]Oord A V D , Li Y , Vinyals O . Representation Learning with Contrastive Predictive Coding[J]. 2018.
- [82]Vaswani A, Shazeer N, Parmar N, et al. Attention is All you Need[C]. neural information processing systems, 2017: 5998-6008.
- [83]张伟. 基于卷积神经网络的轴承故障诊断算法研究[D].哈尔滨工业大学,2017.
- [84]Adhikari A, Ram A, Tang R, et al. Rethinking Complex Neural Network Architectures for Document Classification[C]. north american chapter of the association for computational linguistics, 2019: 4046-4051.
- [85]Gal Y , Ghahramani Z . A Theoretically Grounded Application of Dropout in Recurrent Neural Networks[C]// Data-Efficient Machine Learning workshop, ICML. 2016.
- [86]Merity S , Keskar N S , Socher R . Regularizing and Optimizing LSTM Language Models[J]. 2017.

- [87]Wan L , Zeiler M D , Zhang S , et al. Regularization of Neural Networks using DropConnect[C]// International Conference on Machine Learning. 2013.

攻读硕士学位期间发表的论文及其它成果

（一）发表的学术论文

- [1] . **Chen Y** , Peng G , Zhu Z , et al. A novel deep learning method based on attention mechanism for bearing remaining useful life prediction[J]. Applied Soft Computing, 2019:105919.(SCI,IF:6.27)
- [2] Zhu Z, Peng G, **Chen Y**, et al. A convolutional neural network based on a capsule network with strong generalization for bearing fault diagnosis[J]. Neurocomputing, 2019: 62-75. (SCI,IF:5.00)

致 谢

2020 年是见证历史的一年。在这一年里，新冠肺炎犹如一座大山，将人们困在家里，阻隔了人与人的各种沟通交流，也阻碍了各项学习工作内容的进行，但是人们仍然依靠发达的信息技术继续砥砺前行。而我也幸运地克服了重重困难，根据以往的工作，依靠老师同学的帮助完成了我的硕士毕业论文。

首先，我要由衷感谢我的导师彭高亮教授。自从大二开始加入彭老师的课题组，并参加课题组组会开始，我就感受到彭老师给与我们每一位学生学业上，生活上甚至人生规划道路上的指导和关心。同时，我们也时刻被彭老师忘我的工作热情和严谨的治学态度感染着，在组会上积极交流沟通、迸发灵感；日常学习工作中相互帮助，努力探索实现功能的最优方案。这种刻苦较真的精神以及从多角度思考问题的思维方式是我在实验室中学习到的最宝贵的东西。在此，我在这哈尔滨工业大学百年校庆之际，诚挚地祝愿彭老师身体健康、工作顺利。

同时，我还要感谢实验室里的薛渊老师、陈宏钧以及电信学院的李君宝老师和计算机学院的刘绍辉老师，我在学业上的进步离不开他们指导。此外，感谢实验室的张伟、孙瑜、李传浩、朱智宇、刘世伟、吉孟宇等学长，李思珏、段从繁、孙岩等同学在我进行学业上的工作以及完成论文的过程中给予的帮助和建议。感谢寝室的陈蛟、孙硕、马瑞、王磊、潘大桐等同学给与我的各种帮助。

感谢哈尔滨工业大学，感谢我在哈尔滨工业大学期间遇到的所有的老师、朋友、同学和实验室的学长学弟。在哈尔滨工业大学百年校庆之际，祝愿哈尔滨工业大学及其规格严格、功夫到家的精神随着一代代哈工大人传承和传播。

最后，特别感谢我的父母一直以来的关心和支持，祝愿他们身体健康，万事如意。